



KI in tomedo — anwenden, verstehen, konfigurieren

Sechs KI-Werkzeuge stecken in tomedo. Diese Sammlung ergänzt die Onlinehilfe des Herstellers um das, was beim täglichen Gebrauch zählt — und gibt neun Arbeitsanleitungen weiter, mit denen sich tomedo mit Hilfe einer KI leichter konfigurieren lässt.

Erarbeitet an einer Referenzinstallation · tomedo v1.170 · Stand 22.09.2026

Die Angaben stammen aus einer Installation. Aussagen der Form „Feld leer“ oder „X von Y“ beschreiben diese Referenzinstallation, nicht tomedo. Kein Anspruch auf Vollständigkeit oder Richtigkeit, keine medizinische und keine rechtliche Beratung. tomedo und zollsoft sind Marken der zollsoft GmbH.

Inhalt

Teil 1 · Anwenderhandbuch	4
1 · Wie die KI in tomedo arbeitet	5
2 · Die sechs Werkzeuge im Überblick	6
3 · Die sieben Regeln	8
4 · KI-Soforthilfe	10
5 · Kartei-Chat	12
6 · Sprechstunden-Assistent	15
7 · (KI-) Zusammenfassung	17
8 · LLM-Textgenerator	18
9 · KI-Prompt in der Aktionskette	20
10 · Fragen gut stellen	22
11 · Beispielsammlung	23
12 · Prüfroutine vor dem Speichern	32
13 · Datenschutz in fünf Sätzen	32
14 · Wenn es schiefgeht	33
15 · Weiterlesen	33
Teil 2 · Expertenhandbuch	34
Do's und Don'ts je Werkzeug	35
0 · Lesehinweis	39
1 · Die Landkarte	40
2 · Wie der Kartei-Chat arbeitet	41
3 · Der LLM-Textgenerator	44
4 · Kartei-Chat	49
5 · KI-Prompt in der Aktionskette	51
6 · Sprechstunden-Assistent	54
7 · (KI-) Zusammenfassung	54
8 · KI-Soforthilfe	55
10 · Zweckbestimmung	55

11 · Datenschutz	56
13 · Welcher Pfad wofür	57
14 · Grenzen und Fehlerquellen	60
15 · Offene Fragen	63
16 · Konsequenzen für laufende Vorhaben	66
Anhang A · Quellen	67
 Teil 3 · Konfigurieren	 73
1 · Das Problem, das Skills lösen	74
2 · Skill, Gem, Custom GPT — dasselbe Prinzip, drei Namen	76
3 · Bevor Sie anfangen: drei harte Punkte	77
4 · So arbeiten Sie mit einem Skill	77
5 · Zwei Empfehlungen, die unabhängig vom Skill wirken	78
6 · Der Katalog	79
7 · Eine eigene Anleitung bauen	87
8 · Grenzen	87
9 · Rückmeldung	88
 Teil 4 · Der LLM-Service-Endpunkt	 89
1 · Aufruf, Routen, Parameter	90
2 · Kosten, Denk-Tokens und Budget	92

TEIL 1 · ANWENDEN

Teil 1 · Anwenderhandbuch

alle, die mit den KI-Funktionen in tomedo arbeiten · Version v2.1 · Stand 2026-09-15 ·
Grundlage tomedo Client v1.170.0.16

Für wen. Für alle, die die KI-Funktionen in tomedo benutzen: Medizinerinnen und Mediziner, MFA, Schmerzassistenz, Praxismanagement. Es setzt keine IT-Kenntnisse voraus und verwendet keine Fachsprache aus der KI-Entwicklung.

Worum es geht. Jedes der sechs KI-Werkzeuge in tomedo hat einen engen Einsatzzweck und klare Grenzen. Wer beides kennt, spart Zeit. Wer es nicht kennt, erzeugt Texte, die überzeugend aussehen und nicht stimmen. Dieses Handbuch ordnet deshalb jedem Werkzeug drei Dinge zu: **wofür es gedacht ist, welche Aufgaben es tatsächlich löst und wo es aufhört.**

Die beiden anderen Teile. Teil 2 erklärt, warum die Dinge so sind, mit Messung und Quelle. Teil 3 — der eigentliche Kern dieser Sammlung — beschreibt Skills: vorbereitete Arbeitsanleitungen, mit denen eine KI außerhalb von tomedo bei der Konfiguration hilft.

Verhältnis zur Onlinehilfe. Dieses Handbuch ersetzt die Onlinehilfe nicht, es ergänzt sie. Die Onlinehilfe beschreibt, **was** eine Funktion tut und wo sie liegt. Hier steht, **wie man sie im Alltag benutzt, ohne hineinzufallen** — was in drei von drei Läufen schiefging, welche Formulierung stattdessen trägt, woran man ein falsches Ergebnis erkennt. Wo eine Funktion nur beschrieben werden müsste, steht hier ein Link statt einer zweiten Beschreibung.

1 · Wie die KI in tomedo arbeitet

Sie stellen eine Frage. Ein Sprachmodell liest sie, sucht sich die passenden Daten aus Ihrer Praxissoftware zusammen und formuliert eine Antwort. Der entscheidende Punkt ist der mittlere Schritt: **das Modell entscheidet selbst, wo es nachsieht**.




Abb. 1 Wie eine Frage in tomedo verarbeitet wird

Daraus folgen drei Dinge, die den ganzen Umgang mit diesen Werkzeugen bestimmen.

Ihre Wortwahl steuert die Suche. Klingt Ihre Frage nach Medikation, sieht das Modell in der Medikationsliste nach — und nur dort. Steht die gesuchte Angabe in einem Verlaufstext, findet es sie dann nicht.


Ein „Nein“ ist kein Beweis. Es heißt nur: an der Stelle, an der nachgesehen wurde, stand nichts. Es heißt nicht, dass es nichts gibt.

Das Modell prüft nicht, es formuliert. Es erkennt nicht, ob eine Angabe fehlt. Wo eine Lücke ist, schreibt es etwas Passendes hin. Deshalb steht am Ende jedes Ablaufs Ihre Prüfung, und deshalb ist sie nicht wegzulassen.

2 · Die sechs Werkzeuge im Überblick

#	Werkzeug	Einsatzzweck in einem Satz	Sieht die Akte	Schreibt hinein
1	KI-Soforthilfe	Fragen zur Bedienung von tomedo beantworten	nein	nein
2	Kartei-Chat	aus der Akte eines Patienten Auskunft geben oder Text erzeugen	ja	ja, nach Bestätigung
3	Sprechstunden-Assistent	ein Gespräch als Karteieintrag vorschlagen	ja	ja, nach Freigabe
4	(KI-) Zusammenfassung	einen gespeicherten Brief in ein festes Schema bringen	nur Briefe	ja, nach Bestätigung
5	LLM-Textgenerator	aus Vorlagendaten einen längeren Text bauen	über die Vorlage	nein
6	KI-Prompt in der Aktionskette	eine wiederkehrende KI-Aufgabe automatisch anstoßen	ja	ja

Wo Sie sie finden. KI-Soforthilfe im Fenster *Hilfe & Supportkontakt*. Kartei-Chat, Sprechstunden-Assistent und (KI-) Zusammenfassung unter *tomedo Intelligence*. Der LLM-Textgenerator hängt nicht dort, sondern im Menü **Format** — das ist die häufigste Sucherei. Der KI-Prompt steckt in der Aktionsketten-Konfiguration und begegnet Ihnen im Alltag nur als Bestätigungsdialog.

**Abb. 2** Welches Werkzeug für welche Aufgabe

3 · Die sieben Regeln

1 Keine Patientendaten in die KI-Soforthilfe.

Sie ist für Fragen zur Bedienung von tomedo da und greift auf Handbuch, Wissensdatenbank und Forum zu — nicht auf Ihre Akte. **Teil 2 · §11**

2 Nichts speichern, was Sie nicht gelesen haben.

Bei jedem Werkzeug steht zwischen Vorschlag und Kartei ein Bestätigungsschritt. Der ist keine Formalie. **Teil 2 · §10**

3 Die KI zählt nicht.

Sie sieht nicht alle Einträge, sondern eine Auswahl. Wenn Vollständigkeit zählt, prüfen Sie sie selbst. **Teil 2 · §14**

4 Form erfüllt heißt nicht Inhalt erfüllt.

Eine Antwort kann alle geforderten Überschriften haben und trotzdem einen ganzen Abschnitt auslassen. **Teil 2 · §14**

5 Eine Quellenangabe ist kein Echtheitsbeweis.

Eine Aussage ohne Quelle müssen Sie prüfen — eine mit falsch zugeordneter Quelle aber auch. **Teil 2 · §4**

6 Bei wichtigen Texten zweimal laufen lassen.

Was sich zwischen zwei Durchläufen unterscheidet, ist genau das, was Sie prüfen müssen. **Teil 2 · §14**

7 Bei Störungen ein Ticket, keinen Chat.

Die KI-Soforthilfe ersetzt kein Support-Ticket. **Teil 2 · §8**

Zwei weitere Regeln lassen sich nicht als Merksatz sagen, sondern nur zeigen. Es sind die beiden, an denen im Alltag am meisten schiefgeht.

Regel A · Fragen Sie, statt zu beauftragen. Der Kartei-Chat darf schreiben. Eine Formulierung, die wie ein Arbeitsauftrag klingt, kann als Schreibauftrag verstanden werden.

× **BESSER NICHT**

„**Erfasse** alle Vorbefunde.“

✓ **SO**

„**Nenne** alle Vorbefunde mit Datum.“

× **BESSER NICHT**

„**Trage** die Medikation **zusammen**.“

✓ **SO**

„**Liste** die Medikation **auf**.“

× **BESSER NICHT**

„**Dokumentiere** die letzten drei Befunde.“

✓ **SO**

„**Gib** die letzten drei Befunde **zurück**.“

Regel B · Ein leeres Feld ist gefährlicher als gar kein Feld. Wenn Sie einen Platzhalter in eine Frage setzen und der bleibt leer, sehen Sie eine leere Zeile — das Modell sieht eine Aufgabe und füllt sie. Das Ergebnis ist plausibel, vollständig und falsch.

× **BESSER NICHT**

Abschicken und erst das Ergebnis anschauen

✓ **SO**

Prüfen, ob der Platzhalter gefüllt ist, **bevor** Sie abschicken

× **BESSER NICHT**

Darauf vertrauen, dass eine Lücke als Lücke erkennbar bleibt

✓ **SO**

Einen Vorbehaltssatz danebenstellen, siehe Abschnitt 10

× **BESSER NICHT**

Das Feld mit einem Bindestrich „füllen“

✓ **SO**

Bei leerem Feld den Satz ganz weglassen

4 · KI-Soforthilfe

Einsatzzweck. Auskunft zur Bedienung von tomedo. Die Wissensbasis sind Handbuch, Wissensdatenbank und Forum. **Teil 2 · §8**

Funktionsbeschreibung und Bedienung: Onlinehilfe → KI-Soforthilfe im Fenster Hilfe & Supportkontakt (<https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/hilfe-supportkontakt/>)

Das ist das einzige KI-Werkzeug, das Sie ohne Vorbereitung benutzen können, und das einzige, bei dem eine falsche Antwort keinen Schaden in der Akte anrichtet. Deshalb steht es hier an erster Stelle.

Dafür geeignet

Funktion finden	„In welchem Menü lege ich Terminarten an?“
Fehlermeldung einordnen	„Was bedeutet die Meldung ‚...‘ beim Speichern?“
Einstellung nachschlagen	„Wo hinterlege ich eine Standarddosierung als Favorit?“
Vorgehen erklären lassen	„Wie gebe ich einen Textbaustein für den Kartei-Chat frei?“
Begriff klären	„Was ist der Unterschied zwischen Leistungsfavorit und Leistungskette?“

Grenzen

GRENZEN – UND WAS DAS FÜR SIE HEISST

Keine Patientendaten zulässig	Auch keine Initialen, kein Geburtsjahr, kein Befundtext — Herstellerauflage
Kein Zugriff auf Ihre Akte	Sie kann nicht nachsehen, was bei Ihnen dokumentiert ist
Kein klinisches Wissen	Dosierungen, Leitlinien, Differentialdiagnosen gehören nicht hierher
Kennt Ihre Version nicht von selbst	Kann Funktionen beschreiben, die es bei Ihnen nicht gibt — Version mitnennen
Ersetzt kein Ticket	Bei einer Störung führt nur der Supportweg weiter

✓ SO

- Für Fragen zur Bedienung und für Handlungsanweisungen an tomedo nutzen.
- Für einen neuen Fall den Chat leeren.
- Vorkonfigurierte Prompts als Textbausteine hinterlegen — Freigabe getrennt vom Kartei-Chat.

✗ BESSER NICHT

- Patientendaten oder patientenbezogene Informationen eingeben. Ausdrückliche Herstellerauflage.
- Klinische Fragen stellen — die Wissensbasis ist Handbuch, Wissensdatenbank und Forum.
- Ein Support-Ticket ersetzen, wenn eine Störung vorliegt.

Woran Sie merken, dass etwas nicht stimmt. Eine Antwort beschreibt eine Funktion, die es in Ihrer Version nicht gibt, oder ein Menü, das bei Ihnen anders heißt. Im Zweifel gegen die Onlinehilfe prüfen.

5 · Kartei-Chat

Einsatzzweck. Auskunft aus der Akte eines geöffneten Patienten — und Texte, die auf dieser Akte aufsetzen. Das vielseitigste und zugleich das voraussetzungsreichste Werkzeug. **Teil 2 · §4**

Funktionsbeschreibung und Bedienung: Onlinehilfe → Kartei-Chat (<https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/karteichat/>)

Dafür geeignet

Verlauf überblicken	„Nenne alle Einträge der Typen ANA, BEF und THER der letzten vier Quartale mit Datum.“
Bestimmte Angabe suchen	„In welchen Einträgen ist eine Infiltration dokumentiert?“
Vor dem Termin vorbereiten	„Was ist seit dem letzten Kontakt dokumentiert?“
Kurzbericht entwerfen	„Schreibe einen Kurzbericht an den Hausarzt, drei Absätze.“
Zuarbeit für Anträge	„Nenne alle dokumentierten Therapieversuche mit Zeitraum und Ergebnis.“
Fremdbefund erschließen	„Nenne alle im Anhang genannten Messwerte mit Einheit und Datum.“
Eintrag anlegen	„Lege einen Karteieintrag vom Typ BEF mit dem heutigen Datum an.“

Grenzen

GRENZEN — UND WAS DAS FÜR SIE HEISST

Sucht dort, wo Ihre Wortwahl hinzeigt	Nennen Sie die Karteieintragstypen, sonst rät das Modell
„Nicht dokumentiert“ ist keine Auskunft über die Akte	Steht der Wert nur in einem Anhang, meldet er ihn als fehlend — und sagt nicht dazu, dass er dort nicht nachgesehen hat. Bei Werten aus Fremdbriefen den Anhang ausdrücklich nennen
Er rechnet nicht gegen	Steht in der Akte eine falsche Zahl, kommt sie unverändert zurück. Er bestätigt eine Angabe nicht — er gibt sie weiter
Zeitangaben steuern die Suche nicht zuverlässig	Lassen Sie jedes Datum mitausgeben und prüfen Sie den Zeitraum selbst
Keine Vollständigkeitsgarantie	Für Zählungen und Statistiken ungeeignet
Keine Bewertung, keine Diagnose	Vom Einsatzzweck nicht gedeckt — er gibt wieder, er beurteilt nicht Teil 2 · §10
Eine Aufgabe pro Frage	Zwei Aufgaben ergeben meist eine halbe Antwort auf beide

Der Verlauf wirkt nach

Vor einer neuen Aufgabe den Chat leeren

Darf schreiben

Eine als Auftrag lesbare Abfrage kann etwas anlegen

✓ **SO**

- Typdefinition setzen — den Fachbegriff der Frage in Karteieintragstypen ausdrücken. Der wirksamste Baustein: 3/3 richtig statt 3/3 falsch.
- Einen Vorbehaltssatz ergänzen, sobald ein fester Wert im Prompt steht: der vorgegebene Wert kann unvollständig oder veraltet sein und ist gegen die Akte zu prüfen.
- Abfragen in Frageform stellen — „nenne“, „liste auf“, „gib zurück“.
- Prompts als reine Textbausteine ablegen und über den Reiter Sichtbarkeit freigeben; lässt eine Stelle offen.
- Jede Aussage über die Quellenverknüpfung öffnen und gelesen.
- Beim Anlegen eines eigenen Karteieintragstyps den Variablennamen des Feldes angeben.
- Zwischen Läufen den Chat leeren — sonst wirken Rückbezüge auf die vorige Antwort fort.

✗ **BESSER NICHT**

- Einen leeren oder falsch beschrifteten Platzhalter stehen lassen. Der gefährlichste Fehler: er wird lautlos gefüllt, in drei von drei Läufen falsch und jedes Mal gleich.
- Einen kompletten Textblock als feste Vorgabe mitgeben — dann durchsucht das Modell die Kartei gar nicht mehr.
- Frage-Antwort-Makros in Chat-Prompts verwenden: sie werden als Rohtext weitergereicht.
- Score-Felder oder nicht bearbeitbare zusammengesetzte Textfelder beim Anlegen eigener Karteieinträge angeben.
- „Erfasse“, „trage zusammen“, „lege dar“ in eine Abfrage schreiben — als Schreibauftrag lesbar.
- Eine Zeitangabe im Prompt für eine Abrufsteuerung halten: der Kartei-Abruf kennt nur eine Datumsgrenze.
- Einen Prompt in der KI-Assistenten-Verwaltung löschen, wenn der Textbaustein bleiben soll — er wird mitgelöscht.
- Die Behandler-Attribution ungeprüft übernehmen.

Woran Sie merken, dass etwas nicht stimmt. Ein Datum, das es in der Akte nicht gibt. Eine Diagnose, die zu gut zur Frage passt. Eine Aussage ohne Quellenangabe. Ein Behandlername, der nicht stimmt. Eine Antwort, die auffällig länger oder kürzer ausfällt als sonst — dann ist etwas anders gelaufen. **Auch eine ungewöhnlich lange Antwort ist ein Warnzeichen**, nicht nur eine kurze. Und: eine Erfolgsmeldung ist kein Nachweis. „Erfolgreich erstellt, einschließlich Anhang“ kam zurück — die Datei war trotzdem nicht in der Akte. **Teil 2 · §14**

Den Wert mitgeben, statt ihn suchen zu lassen

Bisher ging es darum, dass der Chat Ihre Akte durchsucht. Es gibt einen zweiten Weg: Sie geben ihm den Wert gleich mit.

Dafür fügen Sie ein **Briefkommando** in das Eingabefeld ein — dasselbe `$[...]$`, das Sie aus Briefvorlagen kennen. tomedo ersetzt es dort nach einer halben Sekunde

durch den Wert aus der Akte. Der Chat muss dann nicht mehr suchen. Er sieht den Wert einfach.

Was Sie davon haben. Das Ärgernis „er findet es nicht, obwohl es dasteht“ verschwindet — für alles, was bei Ihnen ordentlich in Feldern steht.

Was sich dadurch nicht ändert. Er rechnet weiterhin nicht nach. Wir haben ihm eine Akte mit einem falschen Rechenergebnis vorgelegt, alle Daten sichtbar im selben Fenster: Er hat die falsche Zahl übernommen und nichts gemerkt.

Deshalb schreiben Sie einen Satz dazu:

Prüfe die Angabe gegen die Datumsangaben oben. Weicht sie ab, benenne die Abweichung ausdrücklich und nenne beide Zahlen.

Mit diesem Satz fiel der Fehler fast immer auf. Ohne ihn kein einziges Mal. Beides zusammen wirkt: der Wert vor Augen **und** der ausdrückliche Auftrag, ihn zu prüfen.

Zwei Dinge, die Sie wissen sollten.

- **Briefkommandos lesen keine Anhänge.** Steht der Wert nur in einem eingescannten Fremdbrief, hilft nur der normale Weg — den Chat danach fragen und den Anhang ausdrücklich erwähnen.
- **Ein Kommando liefert nur, was bei Ihnen wirklich in Feldern steht.** Was nur im Freitext steht, kommt nicht — und zwar kommentarlos. Lassen Sie sich jedes Kommando einmal ausgeben, bevor Sie sich darauf verlassen.

Und die gute Nachricht dazu. Wir haben dieselbe Akte zweimal geprüft — einmal vorher und einmal, nachdem die Medikation, die Arbeitsunfähigkeit und die Diagnosen ordentlich in die Felder eingetragen waren. Vorher konnte der Chat mit zwei Datenarten arbeiten, danach mit fünf. **Am Chat hatte sich nichts geändert, nur an der Dokumentation.** Was Sie sauber eintragen, können Sie hinterher verwenden — was Sie in den Fließtext schreiben, nicht.

Und ganz praktisch: Diese Kommandos tippt niemand auswendig, den Prüfsatz auch nicht. Legen Sie beides einmal als Textbaustein an. Danach ist es ein Klick.

6 · Sprechstunden-Assistent

Einsatzzweck. Das Gespräch wird aufgenommen, verschriftlicht und nach einer hinterlegten Vorlage zu Karteieintrags-Vorschlägen verarbeitet. **Teil 2 · §6**

Funktionsbeschreibung und Bedienung: Onlinehilfe → Sprechstunden-Assistent (<https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/sprechstunden-assistent/>)

Dafür geeignet

Erstgespräch mitschreiben	Anamnese, Beschwerden, Vorbehandlungen
Verlaufskontrolle	Veränderung seit dem letzten Termin
Aufklärungsgespräch dokumentieren	was besprochen und vereinbart wurde
Angaben des Patienten festhalten	Medikation, wie vom Patienten berichtet

Grenzen

GRENZEN – UND WAS DAS FÜR SIE HEISST

Die Vorlage bestimmt das Ergebnis, nicht Ihr Gespräch	Passt die Gliederung nicht, gehört die Vorlage angepasst
Nur Text-Karteieinträge	Strukturierte Felder werden nicht befüllt
Keine Deutung, keine Diagnosestellung	Er gibt wieder, was gesagt wurde
Nicht auf tomedo iOS verfügbar	Am iPad steht das Werkzeug nicht zur Verfügung
Einwilligung ist Ihre Aufgabe	Die Software holt sie nicht ein

✓ **SO**

- Das neue Analyseverfahren aktivieren — nur damit dürfen eigene Vorlagen Briefkommandos enthalten.
- Die Beschreibung je Karteieintrag als Steuerungsort nutzen: dort gehören Gliederungsachse und Formatvorgabe hin.
- Die Option „Entpersonalisiert“ und den erweiterten Prompt vor dem Rollout durchtesten.
- Gegen die eigenen Audio-Prompts vergleichen, bevor weiter an ihnen gebaut wird (F10).

✗ **BESSER NICHT**

- Auf tomedo iOS damit rechnen — dort nicht verfügbar.
- Andere als Text-Karteieinträge in Vorlagen erwarten.
- Den Vorschlag ungeprüft speichern.
- Eine Interpretation oder Therapieableitung erwarten — dieselbe Zweckbestimmung wie beim Kartei-Chat schließt das aus.

Woran Sie merken, dass etwas nicht stimmt. Inhalte, die im Gespräch nicht vorkamen. Zuordnungen zum falschen Karteieintragstyp. Eine Einordnung statt einer Wiedergabe.

7 · (KI-) Zusammenfassung

Einsatzzweck. Einen gespeicherten Arztbrief — typischerweise einen Fremdbefund — in ein festes Schema bringen: Diagnosen, Medikation, Prozeduren, Procedere. Das Werkzeug ist als Beta gekennzeichnet. **Teil 2 · §7**

Funktionsbeschreibung und Bedienung: Onlinehilfe → (KI-) Zusammenfassung (<https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/ki-zusammenfassung/>)

Dafür geeignet

Entlassbrief erschließen	Diagnosen und Medikation auf einen Blick
Langen Fremdbefund sichten	vor der ausführlichen Lektüre
Übergabe vorbereiten	Procedere aus einem Klinikbrief

Grenzen

GRENZEN — UND WAS DAS FÜR SIE HEISST

Das Schema ist fest	Schlaflaborwerte, Druckwerte, schmerzspezifische Parameter kommen nicht vor
Kein Anlernen, keine Anweisungen	Es gibt keine Frage, die Sie stellen könnten
Kein Nachfassen	Passt es nicht, neu zusammenfassen statt nachbessern
Nur gespeicherte Briefe	Nicht für Karteieinträge oder freie Texte

✓ SO

- Vor jedem Eigenbau an echten Reha- und Klinikbriefen testen (F9).
- Das Ergebnis prüfen, bestätigen und erst dann speichern.
- Bei unbefriedigendem Ergebnis neu zusammenfassen statt nachzubessern.

✗ BESSER NICHT

- Ein Anlernen erwarten — gibt es nicht.
- Ein eigenes Schema erwarten: Diagnosen, Medikation, Prozeduren, Procedere sind fest. AHI, ESS, Druckwerte oder schmerzspezifische Parameter kommen nicht vor.
- Die eigene Extraktionsstrecke abschalten, bevor F9 beantwortet ist.

Woran Sie merken, dass etwas nicht stimmt. Es fehlt etwas, das im Brief steht — das ist meist kein Fehler, sondern das Schema. Wenn Sie solche Werte brauchen, nehmen Sie den Kartei-Chat.

8 · LLM-Textgenerator

Einsatzzweck. Längere, gegliederte Texte zu einem Patienten. Der einzige Weg, bei dem Sie **vor** dem Erzeugen sehen, welche Daten das Modell bekommt. **Teil 2 · §3**

Zu diesem Werkzeug gibt es derzeit keine Seite in der Onlinehilfe — die Beschreibung hier stammt aus der eigenen Installation.

Dafür geeignet

Arztbrief entwerfen	Rohfassung über einen überschaubaren Zeitraum
Ämteranfrage beantworten	wenn die Datenlage vorher geprüft werden soll
Wiederkehrende Briefart	eigener Kontext je Briefart
Datenlage kontrollieren	die aufgelöste Vorlage allein ist schon nützlich

Grenzen

GRENZEN — UND WAS DAS FÜR SIE HEISST

Nimmt nur eine begrenzte Zahl an Datensätzen mit	Bei Mehrjahres-Verläufen fehlt der ältere Teil — und man sieht es dem Text nicht an
Schreibt nicht in die Kartei	Der Rückweg ist die Zwischenablage
Übernimmt nicht die geöffnete Akte	Der Patient wird im Fenster gesucht
Liegt nicht unter tomedo Intelligence	Menü Format

So arbeiten Sie damit.

1. Menü **Format** · **LLM-Textgenerator**.
2. Kontext wählen, zum Beispiel Arztbrief.
3. Patient im Fenster suchen.
4. Vorlage laden — jetzt steht die aufgelöste Vorlage im Fenster.
5. **Diesen Text lesen.** Fehlt etwas? Sind Werte leer? Hier korrigieren.
6. Erzeugen lassen.
7. Kopieren und dort einfügen, wo der Text hingehört.

✓ **SO**

- Die aufgelöste Vorlage vor dem Generieren lesen und korrigieren — das ist der eigentliche Wert dieses Pfads.
- Als erste eigene Anpassung einen Vorbehaltssatz in den System-Prompt aufnehmen.
- Im System-Prompt verlangen, dass der Betrachtungszeitraum benannt wird — das macht die Kappung für die freigebende Ärztin sichtbar.
- Je Briefart einen eigenen Kontext anlegen statt den ausgelieferten zu überschreiben.
- Ausschließlich `$ [...] $`-Briefkommandos verwenden.

✗ **BESSER NICHT**

- Die Mengenkappung übersehen: 14 Diagnosen, 30 Einträge für Anamnese, Befund und Therapie.
- `$ [...] $` und die Makros `{P_NN}` mischen — Vorrang ist nicht dokumentiert (T2).
- Erwarten, dass das Ergebnis in die Kartei wandert: es geht nur in die Zwischenablage.
- Davon ausgehen, dass der Patient aus der offenen Akte übernommen wird — er wird im Fenster gewählt.
- Mehrjahres-Akten darüber verdichten, solange T1 und die Zweckbestimmung offen sind.

Woran Sie merken, dass etwas nicht stimmt. Der Text wirkt vollständig, aber der Verlauf beginnt später, als Sie wissen. Oder eine Diagnose fehlt, die zweifelsfrei in der Akte steht. Beides zeigt sich in Schritt 5, nicht im Ergebnis.

9 · KI-Prompt in der Aktionskette

Einsatzzweck. Eine wiederkehrende KI-Aufgabe automatisch anstoßen, ausgelöst durch ein Ereignis statt durch einen Klick. Technisch ist es kein eigenes Werkzeug, sondern der Kartei-Chat innerhalb der Automatisierung. **Teil 2 · §5**

Funktionsbeschreibung und Bedienung: Onlinehilfe → Aktionsketten, -auslöser, -bedingungen und -fragen (<https://support.tomedo.de/handbuch/tomedo/automatisierung/aktionsketten-ausloeser-bedinung-fragen/>)

Dafür geeignet

Eingehendes Dokument vorsortieren	Art des Dokuments bestimmen und ablegen
Standardtext vorbereiten	Entwurf beim Anlegen eines Termins
Marker setzen	Kennzeichen für eine nachgelagerte Bearbeitung
Mehrstufige Verarbeitung	ein KI-Schritt reicht sein Ergebnis an den nächsten weiter

Grenzen

GRENZEN – UND WAS DAS FÜR SIE HEISST

Ein Bestätigungsdialog muss von Hand bestätigt werden	Ein unbeaufsichtigter Nachtlauf ist damit derzeit nicht möglich
Keine Rückfrage möglich	Alles, was eine Entscheidung verlangt, muss vorher geregelt sein
Karteieintragstyp und -datum sind nicht änderbar	Das Ziel muss vorher stimmen
Läuft ohne Ihren Blick auf das Ergebnis	Regeln für den Leerfall sind Pflicht

Was Sie als Anwender davon merken. Den Bestätigungsdialog. Er erscheint, damit niemand unbemerkt KI-Verarbeitung an Patientendaten auslöst. Bestätigen Sie ihn bewusst und lesen Sie, was dort steht.

✓ SO

- Den Prompt vorher in der Promptverwaltung für Aktionsketten freigeben.
- Das Ergebnis in einem eigenen Kommando ablegen und an Folgeschritte weiterreichen; diese dürfen selbst KI-Prompts sein.
- Vor jedem Marker- und Regex-Nachbau prüfen, ob er angesichts der Ergebnisweitergabe noch nötig ist (F11).
- Blockierende und nicht-blockierende Aktionen in getrennte Unter-Aktionsketten legen.
- Sperrbedingungen einbauen, damit die Kette nicht bei jeder weiteren Änderung erneut feuert.

× BESSER NICHT

- Einen unbeaufsichtigten Stapellauf planen, solange F7 offen ist.
- Den Bestätigungsdialog umgehen wollen — er muss aus Datenschutzgründen manuell bestätigt werden.
- Karteieintragstyp oder -datum per Kette ändern wollen.
- Erwarten, dass „Zurückschreiben“ mehr als den jüngsten Karteieintrag trifft.

Woran Sie merken, dass etwas nicht stimmt. Die Kette läuft, aber nichts passiert — dann wartet meist ein Dialog im Hintergrund. Oder Sie ändern einen Stammdatensatz und die Kette feuert erneut. Beides ist ein Fall für die Kollegen, die die Kette gebaut haben.

10 · Fragen gut stellen

Eine gute Frage an den Kartei-Chat besteht aus vier Teilen. Fehlt einer, scheitert sie auf eine Art, die man der Antwort nicht ansieht.

1 · Sagen Sie, wo gesucht werden soll. Begriffe wie „Intervention“ oder „Vorbefund“ bedeuten für das Modell nichts. Übersetzen Sie sie in Karteieintragstypen.

Als Intervention gelten ausschließlich Karteieinträge der Typen ANA, BEF, THER und VER. Andere Typen bleiben unberücksichtigt.

2 · Sagen Sie, dass gesucht werden soll.

Durchsuche die Karteihistorie des geöffneten Patienten vollständig, bevor du antwortest.

3 · Setzen Sie einen Vorbehaltssatz, wenn Sie feste Werte mitgeben. Ein Vorbehaltssatz sagt dem Modell: *Was ich dir hier vorgebe, ist vielleicht nicht vollständig – prüf das nach und erfinde nichts dazu.* Ohne ihn hält das Modell einen vorgegebenen Wert für unantastbar und ergänzt Fehlendes lieber selbst.

Die oben vorgegebenen Werte können unvollständig oder veraltet sein. Prüfe sie gegen die Kartei. Wenn ein Wert dort nicht belegt ist, schreibe "nicht dokumentiert" – ergänze nichts aus eigenem Wissen.

4 · Eine Aufgabe. Nicht einordnen *und* formulieren. Wenn beides nötig ist, machen Sie zwei Durchgänge.

Nenne alle gefundenen Einträge mit Datum und Typ, chronologisch aufsteigend, als einfache Liste. Keine Bewertung, keine Zusammenfassung.

Wie sich diese vier Teile im Einzelfall auswirken, zeigt die Sammlung im nächsten Abschnitt.

11 · Beispielsammlung

Jedes Paar zeigt eine Formulierung, die im Alltag vorkommt, daneben eine, die funktioniert, und darunter den Grund. Sie müssen die Sammlung nicht durchlesen — springen Sie zu dem Werkzeug, mit dem Sie gerade arbeiten. Für eigene Formulierungen nehmen Sie das nächstliegende Paar und tauschen die Karteieintragstypen aus.

KI-Soforthilfe

Hier geht es nie um Patienten, sondern immer um tomedo. Je genauer Sie die Funktion und den Wortlaut der Meldung nennen, desto brauchbarer die Antwort.

× BESSER NICHT

„Bei Frau M., geb. 1962, lässt sich der Befund vom 3.4. nicht speichern.“

✓ SO

„Beim Speichern eines Karteieintrags vom Typ BEF erscheint die Meldung ‚...‘. Woran kann das liegen?“

Warum. Die KI-Soforthilfe darf keine Patientendaten erhalten — auch nicht als Beispiel, auch nicht abgekürzt. Name und Geburtsjahr genügen für eine Identifizierung.

× BESSER NICHT

„Aktionsketten funktionieren nicht.“

✓ SO

„Eine Aktionskette mit dem Auslöser ‚Stammdaten geändert‘ feuert bei jeder weiteren Änderung erneut. Wie verhindere ich das?“

Warum. Keine Funktion benannt, keine Meldung, kein Verhalten. Die Antwort wird eine allgemeine Einführung, die Ihnen nicht hilft.

× BESSER NICHT

„Welche Dosis Pregabalin ist bei neuropathischem Schmerz üblich?“

✓ SO

Klinische Fragen gehören nicht hierher. Für Bedienfragen: „Wo hinterlege ich eine Standarddosierung als Medikationsfavorit?“

Warum. Die Wissensbasis sind Handbuch, Wissensdatenbank und Forum — keine medizinische Literatur. Sie bekommen eine Antwort, aber keine belastbare.

× **BESSER NICHT**

„Gibt es in tomedo eine Funktion für Serienbriefe?“

✓ **SO**

„Gibt es in tomedo v1.170 eine Funktion für Serienbriefe, und wo finde ich sie im Menü?“

Warum. Ohne Versionsangabe kann die Antwort eine Funktion beschreiben, die es bei Ihnen noch nicht oder nicht mehr gibt.

× **BESSER NICHT**

„Wie lege ich einen Textbaustein an und wie gebe ich ihn für den Kartei-Chat frei und wie baue ich daraus eine Aktionskette?“

✓ **SO**

Nacheinander fragen. Erst: „Wie lege ich einen Textbaustein an?“ Dann: „Wie gebe ich einen bestehenden Textbaustein für den Kartei-Chat frei?“

Warum. Drei Fragen ergeben eine Antwort, die alle drei streift und keine beantwortet.

Kartei-Chat · Fragen an die Akte

Der häufigste Fehler ist nicht ein falsches Wort, sondern eine fehlende Ortsangabe.

Sagen Sie dem Chat, in welchen Karteieintragstypen er suchen soll.

× **BESSER NICHT**

„Was ist mit dem Patienten los?“

✓ **SO**

„Nenne alle Karteieinträge der Typen ANA, BEF und THER aus den letzten vier Quartalen, mit Datum und Typ, chronologisch aufsteigend als Liste.“

Warum. Keine Aufgabe, kein Suchort, kein Format. Sie bekommen eine Erzählung, die Sie nicht gegen die Akte prüfen können.

× **BESSER NICHT**

„Erfasse alle Vorbefunde des Patienten.“

✓ **SO**

„Nenne alle Vorbefunde des Patienten mit Datum und Absender.“

Warum. ‚Erfassen‘ ist in tomedo ein Schreibvorgang. Der Chat darf schreiben — eine Abfrage sollte nie wie ein Arbeitsauftrag klingen.

× **BESSER NICHT**

„Nenne alle Interventionen der letzten zwei Jahre.“

✓ **SO**

„Als Intervention gelten ausschließlich Karteieinträge der Typen THER, VER und PROZ. Durchsuche die Karteihistorie vollständig und nenne alle solchen Einträge mit Datum und Typ.“

Warum. ‚Intervention‘ ist ein Fachbegriff Ihrer Praxis, kein Suchbegriff. Der Chat rät, was gemeint sein könnte.

× **BESSER NICHT**

„Nenne alle Einträge aus dem Jahr 2024.“

✓ **SO**

„Berücksichtige nur Einträge ab dem 01.01.2024. Nenne jeden gefundenen Eintrag mit vollständigem Datum, damit ich den Zeitraum prüfen kann.“

Warum. Eine Jahresangabe im Text ist keine Abrufsteuerung. Das Historienwerkzeug kennt nur ein frühestes Datum — was danach kommt, filtert das Modell selbst, und zwar unzuverlässig.

× **BESSER NICHT**

„Welche Schmerzmittel hat der Patient bekommen?“

✓ **SO**

„Durchsuche die Karteieinträge der Typen THER und VER im Freitext nach Nennungen von Analgetika und nenne jede Fundstelle mit Datum und Wortlaut. Die strukturierte Medikationsliste interessiert hier nicht.“

Warum. Die Frage klingt nach Medikation, also landet sie beim Medikationswerkzeug — und bleibt dort. Nennungen im Verlaufstext werden nicht gefunden.

× **BESSER NICHT**

„Gibt es einen Reha-Bericht?“

✓ **SO**

„Nenne alle Karteieinträge der Typen BRIEF und BEF mit Bezug zu einer Rehabilitation, mit Datum und Absender. Wenn du keinen findest, antworte ‚keine gefunden‘ und nenne, welche Typen du durchsucht hast.“

Warum. Ein „Nein“ ist nie ein Beweis für Abwesenheit — es heißt nur, dass an der geprüften Stelle nichts stand. Ohne Angabe, wo gesucht wurde, ist die Antwort wertlos.

× **BESSER NICHT**

„Fasse die Kartei zusammen.“

✓ **SO**

„Fasse die Kartei in genau vier Abschnitten zusammen: Anlass, bisheriger Verlauf, aktuelle Medikation, offene Punkte. Je Abschnitt höchstens vier Sätze. Ist zu einem Abschnitt nichts dokumentiert, schreibe darunter ‚nicht dokumentiert‘.“

Warum. Ohne Rubriken und Längenvorgabe entscheidet das Modell, was wichtig ist. Zwei Durchläufe ergeben zwei verschiedene Zusammenfassungen.

Kartei-Chat · Text erzeugen

Beim Erzeugen kommt zur Ortsangabe die Formvorgabe hinzu. Und: je genauer Sie sagen, was bei fehlenden Daten passieren soll, desto weniger wird erfunden.

× **BESSER NICHT**

„Schreibe einen Brief.“

✓ **SO**

„Schreibe einen Kurzbericht an den überweisenden Hausarzt. Drei Absätze: Anlass der Vorstellung, bisheriger Verlauf, weiteres Vorgehen. Höchstens 200 Wörter, sachlicher Stil, keine Anrede und keine Grußformel.“

Warum. Kein Adressat, kein Zweck, keine Länge. Das Ergebnis ist ein Text, der zu nichts passt.

× **BESSER NICHT**

„Sortiere die Einträge nach Relevanz und schreibe daraus einen Kurzbericht.“

✓ **SO**

Zwei Durchgänge. Erst: „Nenne die Einträge, absteigend nach Relevanz für die Fragestellung X, als Liste.“ Dann: „Schreibe aus dieser Liste einen Kurzbericht in drei Absätzen.“

Warum. Sortieren ist Einordnen, Schreiben ist Formulieren. Beides in einem Prompt ergibt meist eine halbe Antwort auf beides.

× **BESSER NICHT**

„Diagnosen: \$[diagnosen]\$ — schreibe daraus den Diagnoseabschnitt.“

✓ **SO**

„Diagnosen (vorgegeben): \$[diagnosen]\$ — diese Liste kann unvollständig oder veraltet sein. Prüfe sie gegen die Kartei. Steht dort nichts, schreibe ‚nicht dokumentiert‘. Ergänze nichts aus eigenem Wissen. Schreibe daraus den Diagnoseabschnitt.“

Warum. Liefert der Platzhalter nichts, steht da nur „Diagnosen:“. Das Modell sieht eine Aufgabe und füllt die Lücke mit Plausiblen.

× **BESSER NICHT**

„Verwende keine Fachbegriffe.“

✓ **SO**

„Verwende die Wörter Chronifizierung, Somatisierung und Fibromyalgie nicht. Schreibe stattdessen in Alltagssprache.“

Warum. Ein abstraktes Verbot wirkt nicht — das Modell weiß nicht, welche Wörter gemeint sind.

× **BESSER NICHT**

„Formuliere wie in diesem Beispiel: ‚Der Patient stellte sich erstmals im März 2023 mit lumbalen Schmerzen vor...‘ — aber übernehme den Inhalt nicht.“

✓ **SO**

Gerüst statt Beispiel: „Schreibe nach diesem Muster: ‚Der Patient stellte sich erstmals im [Monat Jahr] mit [Beschwerde] vor.‘ Fülle die eckigen Klammern aus der Kartei.“

Warum. Beispielinhalte tauchen im Ergebnis wieder auf, auch wenn Sie das ausdrücklich verbieten. März 2023 und die lumbalen Schmerzen landen im Brief.

× **BESSER NICHT**

„Fasse dich kurz.“

✓ **SO**

„Höchstens 150 Wörter in genau drei Absätzen.“

Warum. ‚Kurz‘ ist keine Vorgabe. Zwischen zwei Durchläufen schwankt die Länge erheblich.

× **BESSER NICHT**

„Gliedere in Anamnese, Befund, Verlauf, Medikation, Beurteilung, Procedere.“

✓ **SO**

„Gliedere in Anamnese, Befund, Verlauf, Medikation, Beurteilung, Procedere. Jede Rubrik muss erscheinen. Ist zu einer Rubrik nichts belegt, schreibe darunter ausschließlich ‚nicht dokumentiert‘. Nenne am Ende, wie viele Karteieinträge du ausgewertet hast.“

Warum. Sechs Überschriften sind schnell erfüllt — auch dann, wenn unter einer nichts steht oder ein ganzer Block unterschlagen wird. Die Form täuscht Vollständigkeit vor.

Kartei-Chat · in die Kartei schreiben

Schreiben ist der einzige Bereich, in dem ein unklarer Prompt bleibenden Schaden anrichtet. Nennen Sie Ziel und Feld — und lassen Sie sich den Text vorher zeigen.

× **BESSER NICHT**

„Leg das in der Kartei ab.“

✓ **SO**

„Lege einen Karteieintrag vom Typ BEF mit dem heutigen Datum an und schreibe den obigen Text unverändert in das Textfeld.“

Warum. Weder Typ noch Feld benannt. Im günstigen Fall passiert nichts, im ungünstigen landet der Text an einer Stelle, an der ihn niemand sucht.

× **BESSER NICHT**

„Trag die Werte in den Verlaufsbogen ein.“

✓ **SO**

„Lege einen Karteieintrag vom Typ VLF an und setze das Feld mit dem Variablennamen `schmerzNRS` auf den Wert 6.“

Warum. Bei eigenen Karteieintragstypen braucht der Chat den Variablennamen des Feldes, nicht dessen Beschriftung auf dem Bildschirm.

× **BESSER NICHT**

„Schreib den Bericht in die Kartei.“

✓ **SO**

„Zeige mir zuerst den fertigen Bericht im Chat. Schreibe ihn erst dann in die Kartei, wenn ich ausdrücklich ‚eintragen‘ antworte.“

Warum. Der Text wird erzeugt und gespeichert, ohne dass Sie ihn gesehen haben. Der Bestätigungsschritt entfällt faktisch.

Sprechstunden-Assistent · Beschreibung je Karteieintrag

Hier schreiben Sie keinen Prompt in ein Chatfenster, sondern eine Beschreibung in die Vorlage. Sie wirkt bei jedem Gespräch gleich — Ungenauigkeit vervielfältigt sich.

× BESSER NICHT

„Fasse das Gespräch zusammen.“

✓ SO

„Gib den Gesprächsinhalt in vier Abschnitten wieder: aktuelle Beschwerden, Veränderung seit dem letzten Termin, Medikation wie vom Patienten berichtet, vereinbartes Vorgehen.“

Warum. Das Ergebnis ist bei jedem Gespräch anders gegliedert. Nachträgliches Sortieren in der Kartei kostet mehr Zeit, als die Aufnahme spart.

× BESSER NICHT

„Leite eine Verdachtsdiagnose ab.“

✓ SO

„Gib genannte Beschwerden sinngemäß wieder, ohne Bewertung und ohne Einordnung. Diagnosen nur dann, wenn sie im Gespräch ausdrücklich genannt wurden.“

Warum. Eine Deutung ist von der Zweckbestimmung nicht gedeckt. Der Assistent soll festhalten, was gesagt wurde.

× BESSER NICHT

„Schreib das ordentlich auf.“

✓ SO

„Stichpunkte, je Zeile ein Sachverhalt, keine vollständigen Sätze, kein Fließtext. Angaben des Patienten in indirekter Rede.“

Warum. Ohne Formatvorgabe entsteht mal Fließtext, mal eine Stichpunktliste.

(KI-) Zusammenfassung

Dieses Werkzeug nimmt keine Anweisungen entgegen — es gibt keinen Prompt. Die Beispiele zeigen deshalb Erwartungen, die scheitern, und was stattdessen geht.

× BESSER NICHT

Im Anschluss an das Ergebnis nachfassen:
„Ergänze noch die AHI-Werte aus dem Bericht.“

✓ SO

Werte außerhalb des Schemas holen Sie über den Kartei-Chat: „Nenne alle im Anhang genannten Messwerte zur Schlafapnoe mit Einheit und Datum.“

Warum. Das Schema ist fest. Es gibt kein Nachfassen und kein Anlernen — die Aufforderung läuft ins Leere oder erzeugt eine erfundene Ergänzung.

× **BESSER NICHT**

Das Ergebnis im Karteieintrag von Hand nachbessern und speichern.

✓ **SO**

Neu zusammenfassen lassen, das Ergebnis vollständig prüfen und dann unverändert bestätigen. Ergänzungen als eigenen Karteieintrag.

Warum. Eine halb korrigierte Zusammenfassung ist schwerer zu prüfen als eine neue. Man sieht ihr später nicht an, welcher Teil geprüft wurde.

LLM-Textgenerator · System-Prompt

Was Sie hier hineinschreiben, gilt für jeden Lauf in diesem Kontext. Legen Sie je Briefart einen eigenen Kontext an, statt den ausgelieferten zu überschreiben.

× **BESSER NICHT**

„Erfinde nichts hinzu.“

✓ **SO**

„Die vorgegebenen Werte können unvollständig oder veraltet sein. Ist ein Wert nicht belegt, schreibe ‚nicht dokumentiert‘. Ergänze nichts aus eigenem Wissen und ziehe keine Schlüsse aus dem Fehlen einer Angabe.“

Warum. Eine Negativregel ohne Anweisung, was stattdessen zu tun ist. Sie sagt dem Modell nicht, dass die vorgegebenen Werte selbst lückenhaft sein können.

× **BESSER NICHT**

Ohne Zeitraumangabe generieren lassen.

✓ **SO**

„Nenne im ersten Satz den Zeitraum, den die vorliegenden Daten abdecken, in der Form ‚Der Bericht stützt sich auf Dokumentation von TT.MM.JJJJ bis TT.MM.JJJJ.‘“

Warum. Die Vorlage nimmt nur eine begrenzte Zahl an Einträgen mit. Im fertigen Text ist nicht erkennbar, ab wann die Daten reichen — auch nicht für die freigebende Ärztin.

× **BESSER NICHT**

In der Vorlage `$[...]`-Kommandos und `{P_01}`-Makros mischen.

✓ **SO**

Ausschließlich `$[...]` verwenden und die Vorlage nach dem Laden daraufhin durchsehen.

Warum. Es sind zwei verschiedene Platzhaltersysteme. Welches Vorrang hat, ist nicht dokumentiert — das Ergebnis ist nicht vorhersagbar.

× BESSER NICHT

Vorlage laden und sofort auf Generieren klicken.

✓ SO

Den aufgelösten Vorlagentext lesen, leere Werte streichen oder von Hand ergänzen, und erst dann generieren.

Warum. Damit verschenken Sie den einzigen Vorteil dieses Pfads: Sie sehen vorher, was das Modell bekommt.

KI-Prompt in der Aktionskette

Ein Prompt in einer Kette läuft ohne Sie. Alles, was eine Rückfrage oder eine Entscheidung verlangt, muss vorher geregelt sein.

× BESSER NICHT

„Frag mich, wenn etwas unklar ist.“

✓ SO

„Ist die Zuordnung nicht eindeutig, gib ausschließlich `UNKLAR` zurück und schreibe sonst nichts.“

Warum. In der Kette ist niemand da, den man fragen könnte. Das Modell entscheidet selbst — und Sie erfahren nicht, dass es entschieden hat.

× BESSER NICHT

„Fasse den Befund zusammen.“ — ohne Regel für den Leerfall

✓ SO

„Liegt kein Karteieintrag vom Typ BEF der letzten 30 Tage vor, gib ausschließlich `KEIN_BEFUND` zurück. Andernfalls fasse ihn in höchstens fünf Stichpunkten zusammen.“

Warum. Liegt kein passender Eintrag vor, erzeugt das Modell trotzdem einen Text. Die Kette schreibt ihn weg, und niemand merkt es.

× BESSER NICHT

Das Ergebnis direkt im Folgeschritt erwarten, ohne es abzulegen.

✓ SO

Im Aktionsschritt ein Ergebniskommando festlegen und im Folgeschritt genau dieses Kommando verwenden.

Warum. Der Folgeschritt sieht nichts. Das Ergebnis muss in ein eigenes Kommando geschrieben werden, sonst ist es nach dem Schritt verloren.

12 · Prüfroutine vor dem Speichern

Sechs Fragen, dreißig Sekunden. Bei allem, was in die Akte oder in einen Brief geht.

1. **Datum.** Stimmen alle genannten Daten mit der Akte überein?
2. **Namen.** Behandler, Einrichtungen, Medikamente — alles so in der Akte vorhanden?
3. **Vollständigkeit.** Fehlt etwas, von dem Sie wissen, dass es dokumentiert ist?
4. **Quellen.** Trägt jede relevante Aussage eine Angabe, und führt die zum richtigen Eintrag?
5. **Zeitraum.** Deckt die Antwort den Zeitraum ab, den Sie erwartet haben?
6. **Eigenes Wissen.** Steht etwas darin, das plausibel klingt, aber nirgends in der Akte steht?

Ergibt eine dieser Fragen ein Nein: nicht korrigieren lassen, sondern neu laufen lassen.
Nachbesserungen im laufenden Chat schleppen den Fehler meist mit.

13 · Datenschutz in fünf Sätzen

1. Die KI-Verarbeitung läuft **nicht lokal** in der Praxis. **Teil 2 · §11**
2. Kartei-Chat, Sprechstunden-Assistent, (KI-) Zusammenfassung und der KI-Prompt in der Aktionskette **dürfen** patientenbezogene Daten verarbeiten.
3. Die **KI-Soforthilfe darf es nicht** — dort gehören keine Patientendaten hinein, auch nicht in einem Beispiel.
4. Fragt ein Patient, was mit seinen Daten passiert: an die Praxisleitung beziehungsweise den Datenschutzbeauftragten verweisen, nicht aus dem Stegreif antworten.
5. Entsteht der Eindruck, dass Daten in ein Werkzeug geraten sind, in das sie nicht gehören: sofort intern melden.
Das ist kein Vorwurf, sondern ein Meldeweg.

14 · Wenn es schiefgeht

Was Sie sehen	Was meist dahintersteckt	Was Sie tun
Antwort ist leer oder bricht ab	Aufgabe zu groß, oder mehrere Aufgaben in einer Frage	In zwei Schritte teilen
„Dazu liegt nichts vor“, obwohl es etwas gibt	Es wurde an der falschen Stelle gesucht	Karteieintragstypen benennen
Ein Datum oder Name stimmt nicht	Platzhalter war leer, Lücke wurde gefüllt	Neu laufen lassen, Platzhalter prüfen
Antwort wiederholt eine frühere Antwort	Vorheriger Verlauf wirkt nach	Chat leeren, neu starten
Zwei Durchläufe, zwei sehr verschiedene Ergebnisse	Normale Schwankung	Beides prüfen, die belegbare Fassung nehmen
Text ist deutlich kürzer als erwartet	Begrenzte Datenmenge in der Vorlage	Zeitraum einschränken, in Teilen arbeiten
Kette läuft nicht weiter	Bestätigungsdialog wartet im Hintergrund	Fenster suchen und bestätigen
Funktion fehlt im Menü	Rolle oder Version	Bei der Praxis-IT nachfragen

15 · Weiterlesen

Teil 2 · Expertenhandbuch — warum die Dinge so sind: Messungen, Modellwahl, Zweckbestimmung, Datenschutz, offene Punkte.

Teil 3 · Skills, Gems und Custom GPTs — vorbereitete Arbeitsanleitungen für KI außerhalb von tomedo, für Aufgaben, die tomedo nicht abdeckt.

Für alles, was über die Bedienung hinausgeht — eine neue vorbereitete Frage, eine Aktionskette, eine Vorlage — wenden Sie sich an die Kollegen, die diese Dinge pflegen.

TEIL 2 · VERSTEHEN

Teil 2 · Expertenhandbuch

Praxismanagement, Projektverantwortliche, Konfiguratoren · Version v1.0 · Stand
2026-09-15 · Grundlage tomedo Client v1.170.0.16 / Server v1.170-s1356

Für wen. Für alle, die die KI-Funktionen in tomedo nicht nur bedienen, sondern einrichten, bewerten oder verantworten. IT-Kenntnisse sind nicht vorausgesetzt; Bereitschaft, sich mit Belegen und Grenzen zu befassen, schon.

Was dieses Handbuch leistet. Teil 1 sagt, wie man die Werkzeuge bedient. Teil 2 sagt, **warum** — mit Messung, Quelle und Datum. Jede Aussage traegt eine Kennzeichnung: `[Hersteller, TT.MM.JJJJ]` stammt aus der Onlinehilfe oder von einem Mitarbeiter des Herstellers, `[Referenzinstallation, TT.MM.JJJJ]` aus eigenen Laufen, `[Export]` und `[UI]` aus der eigenen Installation, `[Fremdbericht]` aus dem Nutzerforum. Was nicht belegt ist, steht als *plausibel* oder *zu evaluieren* da.

Was es nicht leistet. Es veroeffentlicht kein Herstellerwissen. Wo der genaue Umfang interner Funktionen bekannt, aber nicht veroeffentlicht ist, beschreibt dieses Handbuch die Struktur und die praktischen Folgen — nicht die Liste. Das zu veroeffentlichen ist Sache des Herstellers.

Verhältnis zur Onlinehilfe. Was eine Funktion tut, steht in der Onlinehilfe des Herstellers und wird hier nicht wiederholt. Dieses Handbuch trägt zusammen, was sich beim Benutzen gezeigt hat — Messreihen, Grenzen, Fehlerbilder — und verweist für die Funktionsbeschreibung auf die jeweilige Handbuchseite (Anhang A).

Der LLM-Service-Endpunkt hat dieses Handbuch verlassen. Er betrifft ausschliesslich die Praxis-IT und steht jetzt als eigener, bewusst zurückgenommener Teil 4 am Ende der Sammlung.

Do's und Don'ts je Werkzeug

Acht Bloecke, einer je Werkzeug plus ein uebergreifender.

Für alle Pfade

Gilt unabhängig davon, welches Werkzeug Sie öffnen.

✓ SO

- Die Gliederungsachse in die Strukturvorgabe schreiben — nicht nur die Rubrikzahl.
- Vollständigkeit als eigenes Prüfkriterium führen, getrennt von der Frage nach Richtigkeit.
- Zwei bis drei Wiederholungen fahren und den Diff als Prüfliste verwenden.
- Bei Modellvergleichen mindestens 15 Läufe je Arm und Streuungsmaße mitberichten.
- Jede kostenverursachende Messung mit hartem Kostendeckel und vorher getestetem Abbruchweg.

× BESSER NICHT

- Mittelwerte ohne Streuung berichten — zwei Ausreißer haben bei n=5 den Befund umgedreht.
- Formale Kriterien für Vollständigkeit halten: ein Lauf erfüllte alle sechs und ließ einen von drei Blöcken weg.
- Einen Modellwechsel als Lösung für Fachfehler ansetzen — in der Blindrunde trat keiner auf.
- Die Selbstauskunft des Modells als Prüfergebnis werten.

Belege: §14, §16

Kartei-Chat

Agent mit Werkzeugebene. Er darf lesen und schreiben.

✓ **SO**

- Typdefinition setzen — den Fachbegriff der Frage in Karteieintragstypen ausdrücken. Der wirksamste Baustein: 3/3 richtig statt 3/3 falsch.
- Einen Vorbehaltssatz ergänzen, sobald ein fester Wert im Prompt steht: der vorgegebene Wert kann unvollständig oder veraltet sein und ist gegen die Akte zu prüfen.
- Abfragen in Frageform stellen — „nenne“, „liste auf“, „gib zurück“.
- Prompts als reine Textbausteine ablegen und über den Reiter Sichtbarkeit freigeben; lässt eine Stelle offen.
- Jede Aussage über die Quellenverknüpfung öffnen und gegenlesen.
- Beim Anlegen eines eigenen Karteieintragstyps den Variablennamen des Feldes angeben.
- Zwischen Läufen den Chat leeren — sonst wirken Rückbezüge auf die vorige Antwort fort.

✗ **BESSER NICHT**

- Einen leeren oder falsch beschrifteten Platzhalter stehen lassen. Der gefährlichste Fehler: er wird lautlos gefüllt, in drei von drei Läufen falsch und jedes Mal gleich.
- Einen kompletten Textblock als feste Vorgabe mitgeben — dann durchsucht das Modell die Kartei gar nicht mehr.
- Frage-Antwort-Makros in Chat-Prompts verwenden: sie werden als Rohtext weitergereicht.
- Score-Felder oder nicht bearbeitbare zusammengesetzte Textfelder beim Anlegen eigener Karteieinträge angeben.
- „Erfasse“, „trage zusammen“, „lege dar“ in eine Abfrage schreiben — als Schreibauftrag lesbar.
- Eine Zeitangabe im Prompt für eine Abrufsteuerung halten: der Kartei-Abruf kennt nur eine Datumsgrenze.
- Einen Prompt in der KI-Assistenten-Verwaltung löschen, wenn der Textbaustein bleiben soll — er wird mitgelöscht.
- Die Behandler-Attribution ungeprüft übernehmen.

Belege: karteichat-prompting, §14, §2, §4

Sprechstunden-Assistent

Aufnahme, Transkript, Analyse nach Vorlage, Vorschlag als Karteieintrag.

✓ **SO**

- Das neue Analyseverfahren aktivieren — nur damit dürfen eigene Vorlagen Briefkommandos enthalten.
- Die Beschreibung je Karteieintrag als Steuerungsort nutzen: dort gehören Gliederungsachse und Formatvorgabe hin.
- Die Option „Entpersonalisiert“ und den erweiterten Prompt vor dem Rollout durchtesten.
- Gegen die eigenen Audio-Prompts vergleichen, bevor weiter an ihnen gebaut wird (F10).

✗ **BESSER NICHT**

- Auf tomedo iOS damit rechnen — dort nicht verfügbar.
- Andere als Text-Karteieinträge in Vorlagen erwarten.
- Den Vorschlag ungeprüft speichern.
- Eine Interpretation oder Therapieableitung erwarten — dieselbe Zweckbestimmung wie beim Kartei-Chat schließt das aus.

Belege: §10, §14, §15, §6

LLM-Textgenerator

Menü Format. Der einzige Pfad, bei dem Sie sehen, was das Modell bekommt.

✓ SO

- Die aufgelöste Vorlage vor dem Generieren lesen und korrigieren — das ist der eigentliche Wert dieses Pfads.
- Als erste eigene Anpassung einen Vorbehaltssatz in den System-Prompt aufnehmen.
- Im System-Prompt verlangen, dass der Betrachtungszeitraum benannt wird — das macht die Kappung für die freigebende Ärztin sichtbar.
- Je Briefart einen eigenen Kontext anlegen statt den ausgelieferten zu überschreiben.
- Ausschließlich `$[...] $`-Briefkommandos verwenden.

✗ BESSER NICHT

- Die Mengenkappung übersehen: 14 Diagnosen, 30 Einträge für Anamnese, Befund und Therapie.
- `$[...] $` und die Makros `{P_NN}` mischen — Vorrang ist nicht dokumentiert (T2).
- Erwarten, dass das Ergebnis in die Kartei wandert: es geht nur in die Zwischenablage.
- Davon ausgehen, dass der Patient aus der offenen Akte übernommen wird — er wird im Fenster gewählt.
- Mehrjahres-Akten darüber verdichten, solange T1 und die Zweckbestimmung offen sind.

Belege: §10, §3

(KI-) Zusammenfassung

Beta. Fasst gespeicherte Arztbriefe in ein festes Schema.

✓ SO

- Vor jedem Eigenbau an echten Reha- und Klinikbriefen testen (F9).
- Das Ergebnis prüfen, bestätigen und erst dann speichern.
- Bei unbefriedigendem Ergebnis neu zusammenfassen statt nachzubessern.

✗ BESSER NICHT

- Ein Anlernen erwarten — gibt es nicht.
- Ein eigenes Schema erwarten: Diagnosen, Medikation, Prozeduren, Procedere sind fest. AHI, ESS, Druckwerte oder schmerzspezifische Parameter kommen nicht vor.
- Die eigene Extraktionsstrecke abschalten, bevor F9 beantwortet ist.

Belege: §15, §16, §7

KI-Prompt in der Aktionskette

Keine eigene Engine — die Kartei-Chat-Funktionen in der Automatisierung.

✓ **SO**

- Den Prompt vorher in der Promptverwaltung für Aktionsketten freigeben.
- Das Ergebnis in einem eigenen Kommando ablegen und an Folgeschritte weiterreichen; diese dürfen selbst KI-Prompts sein.
- Vor jedem Marker- und Regex-Nachbau prüfen, ob er angesichts der Ergebnisweitergabe noch nötig ist (F11).
- Blockierende und nicht-blockierende Aktionen in getrennte Unter-Aktionsketten legen.
- Sperrbedingungen einbauen, damit die Kette nicht bei jeder weiteren Änderung erneut feuert.

✗ **BESSER NICHT**

- Einen unbeaufsichtigten Stapellauf planen, solange F7 offen ist.
- Den Bestätigungsdialog umgehen wollen — er muss aus Datenschutzgründen manuell bestätigt werden.
- Karteieintragstyp oder -datum per Kette ändern wollen.
- Erwarten, dass „Zurückschreiben“ mehr als den jüngsten Karteieintrag trifft.

Belege: tomedo-aktionsketten, §14, §5

KI-Soforthilfe

Im Fenster Hilfe & Supportkontakt. Für Produkt- und Bedienfragen.

✓ **SO**

- Für Fragen zur Bedienung und für Handlungsanweisungen an tomedo nutzen.
- Für einen neuen Fall den Chat leeren.
- Vorkonfigurierte Prompts als Textbausteine hinterlegen — Freigabe getrennt vom Kartei-Chat.

✗ **BESSER NICHT**

- Patientendaten oder patientenbezogene Informationen eingeben. Ausdrückliche Herstellerauflage.
- Klinische Fragen stellen — die Wissensbasis ist Handbuch, Wissensdatenbank und Forum.
- Ein Support-Ticket ersetzen, wenn eine Störung vorliegt.

Belege: §4, §8

o · Lesehinweis

Jede Aussage trägt Status **und Quellendatum**. v0.1 dieses Handbuchs hat elf Monate alte Forumsaussagen als Gegenwart geführt und daraus eine falsche Architekturthese abgeleitet — daher die Pflicht zum Datum.

Status	Bedeutung
[Hersteller, TT.MM.JJJJ]	Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters
[UI, 13.09.2026]	aus der laufenden Instanz erhoben, tomedo v1.170.0.16
[Export, 13.09.2026]	Tool-Export der eigenen Installation
[Referenzinstallation, TT.MM.JJJJ]	eigene Messung mit protokollierten Läufen
[Fremdbericht, TT.MM.JJJJ]	Forums-Erfahrungsbericht, nicht bestätigt
PLAUSIBEL / ZU EVALUIEREN	abgeleitet / offen

1 · Die Landkarte




Abb. 3 Die KI-Oberflächen in tomedo v1.170

Dazu ein KI-Generator im Patientenformular-Bereich und die Spracherkennung als eigener Zweig — hier nicht behandelt. ¹

Der KI-Prompt in der Aktionskette ist keine eigene Engine, sondern bringt die Kartei-Chat-Funktionen in die Automatisierung. ¹

BELEGE ZU DIESEM KAPITEL

- 1 Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔

2 · Wie der Kartei-Chat arbeitet

Der Kartei-Chat ist kein Suchfeld. Er ist ein Sprachmodell, das eine Aufgabe in Schritten abarbeitet und dabei **Funktionen der Praxissoftware aufruft** — ähnlich wie ein Mitarbeiter, der nacheinander verschiedene Fenster öffnet, weil in jedem etwas anderes steht. Welche Funktion er aufruft, entscheidet er selbst, anhand Ihrer Formulierung.

Das ist die wichtigste Eigenschaft dieses Werkzeugs, und aus ihr folgt fast alles Weitere.




Abb. 4 Die Zugriffsarten des Kartei-Chats

Die vier Zugriffsarten

Art	Was dahintersteckt	Warum das zählt
Lesen	Verlaufseinträge, strukturierte Listen wie Medikation oder Labor, Anhänge und Dokumente	Jede Art ist ein eigener Zugriff. Eine Frage landet bei einem davon — und bleibt dort
Schreiben	Karteieinträge anlegen und ändern, Formulare öffnen und vorbefüllen	Eine Abfrage, die wie ein Auftrag klingt, kann etwas anlegen
Bedienen	Fenster öffnen, navigieren, Vorgänge anstoßen	Die Reichweite geht über Auskunft hinaus
Allgemeiner Datenzugriff	eine nicht auf einzelne Fachbereiche beschränkte Ebene	Die Reichweite ist breiter als die offensichtlichen Funktionen vermuten lassen

Der Hersteller hat den genauen Umfang dieser Ebene nicht veröffentlicht. Für die Praxis ist die Struktur entscheidend, nicht die Liste: **es gibt Lesezugriffe, es gibt Schreibzugriffe, und die Schreibseite ist nicht auf wenige Sonderfälle beschränkt.**

Fünf Konsequenzen für die tägliche Arbeit

- 1 · Ein „Nein“ ist immer quellengebunden.** Die Antwort bezieht sich auf den Zugriff, den das Modell gewählt hat. Stand dort nichts, lautet die Antwort „nichts gefunden“ — auch dann, wenn die Angabe an anderer Stelle sehr wohl dokumentiert ist. Eine Abwesenheitsaussage ist deshalb nie ein Beweis. ¹
- 2 · Die Wortwahl steuert den Zugriff.** Eine Frage, die nach Medikation klingt, landet beim strukturierten Medikationszugriff und bleibt dort. Nennungen im Verlaufstext werden dann nicht gefunden — nicht, weil sie unauffindbar wären, sondern weil dort gar nicht gesucht wurde. Wer den Volltext meint, muss das sagen und die Eintragstypen benennen. ¹
- 3 · Zeitangaben im Text sind keine Abrufsteuerung.** Der Abruf der Kartei kennt eine Datumsgrenze, aber keinen inhaltlichen Filter. Was Sie an Zeitraum, Stichwort oder Kategorie in die Frage schreiben, wendet das Modell nachträglich auf das an, was es bekommen hat — und zwar nicht zuverlässig. Lassen Sie sich jedes Datum mitausgeben und prüfen Sie den Zeitraum selbst. ²
- 4 · Die Anhangsanalyse sieht das Gespräch nicht.** Wird ein Dokument ausgewertet, geschieht das in einem eigenen Zusammenhang. Vorgaben, die Sie vorher im Chat gemacht haben, wirken dort nicht. Was für die Dokumentauswertung gelten soll, muss in derselben Anweisung stehen. ²
- 5 · Jede Formulierung, die als Auftrag lesbar ist, ist ein Risiko.** Das Modell unterscheidet nicht zwischen Ihrer Absicht und dem Wortlaut. „Erfasse“, „trage zusammen“, „lege dar“ sind in der Praxisprache Schreibvorgänge. Sicher sind „nenne“, „liste auf“, „gib zurück“. ¹

Was daraus für Prompts folgt

Vier Bestandteile machen den Unterschied zwischen einer Frage, die funktioniert, und einer, die auf eine schwer erkennbare Art scheitert:

Bestandteil	Wirkung
Typdefinition — Fachbegriff in Karteieintragstypen übersetzen	der wirksamste einzelne Hebel; steuert, wo gesucht wird
Suchanweisung — ausdrücklich verlangen, dass die Kartei durchsucht wird	verhindert, dass nur der sichtbare Ausschnitt verwendet wird
Vorbehaltssatz — sobald feste Werte mitgegeben werden	ohne ihn gilt ein vorgegebener Wert als unantastbar, und Lücken werden gefüllt
Eine Aufgabe — einordnen oder formulieren, nicht beides	zwei Aufgaben ergeben eine halbe Antwort auf beide

Die praktische Ausformulierung dieser vier Bestandteile steht in Teil 1, Abschnitt 10, die Gegenüberstellungen in Teil 1, Abschnitt 11.

Abgrenzung

Der Hersteller beschreibt den Kartei-Chat als Werkzeug zur Auskunft und Dokumentationsunterstützung, nicht zur Beurteilung. Eine Interpretation, eine Verdachtsdiagnose oder eine Therapieempfehlung ist von der Zweckbestimmung nicht gedeckt — unabhängig davon, ob das Modell sie liefern würde. ³ Was das für laufende Vorhaben bedeutet, steht in §10.

BELEGE ZU DIESEM KAPITEL

- 1 **Referenzinstallation, 08.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↵
- 2 **Export, 13.09.2026** Tool-Export der eigenen Installation Quellenregister A.3 ↵
- 3 **Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↵

3 · Der LLM-Textgenerator

Menüleiste: **Format** › **LLM-Textgenerator**, unterhalb von **Schrift** und **Text**.¹ Ein ungewöhnlicher Pflegeort — wer ihn sucht, sucht zuerst unter **Aktion** oder **Verwaltung**.

Sehr wahrscheinlich die Oberfläche zu derselben Textgenerierung, die auch der Kartei-Chat nutzt, deren Beschreibung dasselbe Verfahren nennt: vordefinierter Kontext, hinterlegte Briefkommandos und Textbausteine werden mit den Patientendaten aufgelöst und mit einem kontextgebundenen System-Prompt zu einem Text generiert.² · **PLAUSIBEL** Damit wäre derselbe Generator auch aus Chat und Aktionskette aufrufbar — **nicht geprüft** (T3).

Ablauf




Abb. 5 Ablauf im LLM-Textgenerator

Drei Eigenschaften bestimmen den Arbeitsablauf ¹:

1. **Der Patient wird im Fenster gewählt**, nicht aus der offenen Akte übernommen — der Generator läuft unabhängig vom Kartei-Kontext.
2. **Die aufgelöste Vorlage ist editierbar, bevor generiert wird**. Man sieht, was das Modell bekommt, und kann es korrigieren. Das ist der entscheidende Unterschied zum Chat.
3. **Das Ergebnis geht nicht in die Kartei**, sondern nur in die Zwischenablage. Kein Schreibzugriff, keine Vidierungsfrage.

Der Kontext-Editor




Abb. 6 Der Kontext-Editor: System-Prompt und Vorlage

Feld 1, System-Prompt. Der ausgelieferte Arztbrief-Kontext weist eine Arztrolle zu und stellt sieben Regeln auf: im Stil eines Arztes schreiben, medizinische Fachsprache verwenden, mit den Überschriften Anamnese, Befund, Diagnose und Therapie strukturieren, in ganzen Sätzen formulieren, für ärztliche Handlungen die Passivform nutzen, präzise und vollständig sein, keine Informationen hinzuerfinden. ¹

Feld 2, Textbaustein-Vorlage. Die Datengrundlage, gekürzt:

```
Patient: ${pvoll}$
Geburtsdatum: ${pgl}$ (${palter_formatiert}$, ${pMW}$)

Diagnosen:
${x ddi,dia inf _ 14 NN NNJN NNNN invTimemitICD}$

Anamnese, Befunde und bisheriger Verlauf:
${x ana,bef,the inf _ 30 NN NNJN NNNN invTime}$

Dauermedikation:
${medikamentenplan}$

Allergien: ...
```

¹

Zwei Platzhaltersysteme nebeneinander. Der Dialog nennt zusätzlich Makro-Befehle der Form `{P_NN}`, `{P_VN}`, `{Diagnose}`, die beim Laden automatisch ersetzt werden. ¹ Verhältnis und Vorrang zu den `$[...]$`-Briefkommandos sind **nicht dokumentiert** (T2). Bis dahin: nur `$[...]$` verwenden.

Das ist unsere Anker-Architektur als Produktfunktion

Skill-Baustein	Entsprechung im Generator
Anker	Briefkommandos in der Vorlage
Aufgabe	System-Prompt
Typdefinition	Kommando-Auswahl je Rubrik (<code>ana,bef,the</code> gegen <code>ddi,dia</code>)
Vorbehaltssatz	fehlt in der Auslieferung

Der Vorbehaltssatz fehlt. „Erfinde keine Informationen hinzu“ ist eine Negativregel, kein Vorbehalt. Ein Vorbehaltssatz sagt dem Modell, dass die **vorgegebenen Werte selbst** unvollständig oder veraltet sein können und gegen die Akte zu prüfen sind. Ohne ihn gilt der belegte Fehlerkatalog: ein leerer oder falsch beschrifteter Anker wird lautlos übernommen. ³

HINWEIS **Erste Anpassung an jedem eigenen Kontext:** Vorbehaltssatz in den System-Prompt aufnehmen.

Die Kappung — die wichtigste Grenze

Die ausgelieferte Vorlage kappt **mengenbasiert**: 14 Diagnosen, 30 Einträge für Anamnese, Befund und Therapie. ¹

Dreissig Einträge decken bei einer aktiven Schmerzakte wenige Quartale ab. Eine Mehrjahres-Betreuung wird **stillschweigend abgeschnitten** — das Modell erfährt nicht, dass etwas fehlt, und der System-Prompt verlangt zugleich Vollständigkeit.

HINWEIS **Mengenkappung plus Vollständigkeitsanspruch ist genau die Konstellation, in der stiller Inhaltsverlust entsteht.** Siehe §14. Im System-Prompt verlangen, dass der Betrachtungszeitraum benannt wird — ein Satz wie „Der Bericht stützt sich auf die letzten N dokumentierten Einträge“ macht die Kappung für die freigebende Ärztin sichtbar.

Abgrenzung zum externen Arztbrief-Verfahren

Dimension	LLM-Textgenerator	externer Export-Weg
Datenschutz	kein Anonymisierungsschritt	Anonymisierung als Gate
Datengrundlage	mengengekapt, 14 / 30	vollständiger Aktenexport
Eingriff vor dem Lauf	Vorlage editierbar	Export editierbar
Iteration	ein Durchlauf, dann neu	Review-Runden im Dialog
Wiederhollauf-Diff	nicht vorgesehen	etabliert
Zielstruktur	Anamnese, Befund, Diagnose, Therapie	frei, hausspezifisch
Rückweg	Zwischenablage	Zwischenablage

Für Briefe aus einem überschaubaren Zeitraum ist der Generator der schnellere Weg — und er entfernt den Anonymisierungsaufwand vollständig. Für Mehrjahres-Verdichtung bleiben zwei offene Punkte: die Mengenkappung (T1) und die Zweckbestimmung (§10).

Details und die vollständige Testliste T1–T7: [karteichat-prompting/references/llm-textgenerator.md](#).

BELEGE ZU DIESEM KAPITEL

- 1 UI, 13.09.2026** Erhebung aus der laufenden Instanz, tomedo v1.170.0.16 Quellenregister A.3 ↩
- 2 Export, 13.09.2026** Tool-Export der eigenen Installation Quellenregister A.3 ↩
- 3 Referenzinstallation, 08.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↩

4 · Kartei-Chat

Nicht für tomedo iOS. ¹

Zweckbestimmung: unterstützt beim **Auffinden vorhandener Informationen**; dient ausdrücklich **nicht** der Unterstützung bei Diagnose und Therapie durch Auswertung und Interpretation. ¹ Siehe **§10**.

Quellenverknüpfung: Jede gelieferte Information wird mit ihrer Quelle verknüpft, dargestellt als Kürzel wie [ANA] ; ein Klick öffnet den Eintrag. Lässt sich eine Information **nicht** verknüpfen, muss der Nutzer sie zusätzlich verifizieren. ¹

HINWEIS Die offizielle Halluzinations-Erkennungsregel — sie ersetzt den Wiederhollauf aber nicht. Ein falsch zugeordneter Eintrag trägt ebenfalls eine Quellenangabe; unsere belegte Konfabulationsklasse der Behandler-Attribution ist genau von dieser Art. ²

Liest: Karteieinträge inklusive Anhänge, Formulare (PatF, AU, Überweisung), Patientenkurzinfos, Laborbefunde, Diagnosen, Medikamente, auch handschriftliche iPad-Notizen. Bild- und Dokumentanalyse ab v1.164 (PDF, JPEG, PNG). ¹

Schreibt: EBM auf den KV-Schein, Erinnerungen, Nachrichten, Aufgaben, Karteieinträge (Text und Custom), Formulare öffnen und vorbefüllen, Briefkommandos verwenden. ¹

CKE anlegen braucht den **Variablennamen** des Feldes. Score-Felder und nicht editierbare zusammengesetzte Textfelder dürfen **nicht** angegeben werden. BMI und Blutdruck möglich. **Formular-Vorbefüllung** zusätzlicher Felder derzeit nur bei AU (1/E) und Überweisung (6/E). ¹

Prompts als Textbausteine: Freigabe über Reiter **Sichtbarkeit**, getrennt für Kartei-Chat und Support-Chat, **nutzerübergreifend**. Platzhalter lässt eine Stelle offen. ¹

ACHTUNG **Nur reine Textbausteine.** Auswahl- und **Frage-Antwort-Makros werden nicht ausgeführt**, sondern als Rohtext weitergereicht. ¹ Unsere Physio-Textbausteine mit 221 Dialogfragen sind als Chat-Prompts unbrauchbar.

Formatierung trägt nicht. Zeichenformatierung eines Bausteins liegt in der RTF-Ebene und erzeugt keinen Zuwachs im Rohtext. `$_[karteiEintragWert <Typ> text _ N]$_` liefert reinen Text ohne Auszeichnung, und ein Karteieintragstyp mit eigener Formatierung überschreibt die des Bausteins — auch nachträglich beim Umhängen eines bestehenden Eintrags. Struktur, die eine KI oder ein Brief später verwerten soll, muss deshalb aus **Zeichen** bestehen: Label, Doppelpunkt, Zeilenführung — nicht aus Fettschrift. *[Messung Q-M10]*

Promptverwaltung: Verwaltung › Sprechstunden-Assistent › KI-Assistenten-Verwaltung. Ein dort gelöschter Eintrag löscht den **Textbaustein**. ¹

BELEGE ZU DIESEM KAPITEL

- 1 Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters [Quellenregister A.1 ↗](#)
- 2 Referenzinstallation, 08.09.2026** eigene Messung mit protokollierten Läufen [Quellenregister A.3 ↗](#)

5 · KI-Prompt in der Aktionskette




Abb. 7 KI-Prompt in der Aktionskette

Freigabe in der Promptverwaltung ist Voraussetzung. Das Ergebnis lässt sich in einem Kommando ablegen und an Folgeschritte weiterreichen; diese können selbst KI-Prompts sein. ¹

HINWEIS Der Bestätigungsdialog muss aus Datenschutzgründen immer manuell bestätigt werden; nur dann läuft die Kette weiter. ¹

Vorhaben	Tragfähig?
Interaktive Kette, Nutzer sitzt davor	ja
Nächtlicher Stapellauf ohne Aufsicht	nein, solange F7 offen
Statistik-Ergebnisliste zeilenweise	nur mit Aufsicht PLAUSIBEL

Die Ergebnisweitergabe leistet, was im Forum per Marker und Regex nachgebaut wird. Vor jedem Nachbau prüfen, ob er noch nötig ist (F11).

BELEGE ZU DIESEM KAPITEL

¹ Hersteller, 11.09.2026 Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔

6 · Sprechstunden-Assistent




Abb. 8 Sprechstunden-Assistent: von der Aufnahme zum Karteieintrag

Zweckbestimmung wie beim Kartei-Chat. Nicht für iOS; Registrierung nötig. ¹

Vorlagen brauchen Namen, Kürzel und mindestens einen Karteieintrag. Die **Beschreibung je Karteieintrag** steuert Inhalt und Formatierung. Derzeit nur Text-Karteieinträge. Mitgeliefert wird eine Standardvorlage für das Erstgespräch. **Formatierungsregeln:** Sprachstil, Fliesstext gegen Stichpunkte, Option **Entpersonalisiert**, dazu ein erweiterter Prompt. ¹

Das neue Analyseverfahren deaktiviert das alte: mehr Möglichkeiten, besseres Modell, schnellere Analyse. **Nur damit können eigene Vorlagen Briefkommandos enthalten.** ¹

HINWEIS Damit existiert die Anker-Architektur auch hier — Vorlage plus fest vorgegebener Wert plus Beschreibung je Karteieintrag. **Ernsthaftester Konkurrent zu unseren `<audio-*>`-Prompts.**

BELEGE ZU DIESEM KAPITEL

¹ **Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔

7 · (KI-) Zusammenfassung

Beta. Fasst in der Kartei gespeicherte **Arztbriefe** strukturiert zusammen; das Schema ist bewusst **fest**: Diagnosen, Medikation, Prozeduren, Procedere. Button `zusammenfassen` am geöffneten Dokument, prüfen, bestätigen und speichern. Neu zusammenfassen möglich, Anlernen nicht. ¹

HINWEIS Die Bordinhalt-Antwort auf die Fremdbefund-Extraktion. Einschränkung ist das feste Schema: AHL, ESS, Druckwerte oder schmerzspezifische Parameter gibt es hier nicht. Vor jedem Eigenbau an echten Reha-Briefen testen (F9).

BELEGE ZU DIESEM KAPITEL

¹ **Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔

8 · KI-Soforthilfe

Im Fenster **Hilfe & Supportkontakt**. Greift auf Handbuch, interne Wissensdatenbanken und das Nutzerforum zu; beruht laut Hersteller auf denselben mathematischen Grundlagen wie der Kartei-Chat. ¹

ACHTUNG Keine Patientendaten eingeben. ¹

BELEGE ZU DIESEM KAPITEL

¹ **Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔

10 · Zweckbestimmung

Für Kartei-Chat und Sprechstunden-Assistent schliesst der Hersteller dasselbe aus: Unterstützung bei Diagnose und Therapie durch **Auswertung und Interpretation** der Daten. ¹

Vorhaben	Innerhalb der Zweckbestimmung?
Wertabfrage, Verlaufszusammenfassung	ja
Fremdbefund in feste Rubriken überführen	ja
Gespräch in Anamnese, Befund, Therapie gliedern	ja
Mehrjahres-Akte zu einem Verlaufsnarrativ verdichten	fraglich
Therapievorschlag ableiten	nein

² Keine Rechtsauskunft. Erklärt nebenbei, warum die (KI-)Zusammenfassung ein **festes** Schema hat und der Textgenerator mengengekappt ausgeliefert wird.

BELEGE ZU DIESEM KAPITEL

¹ **Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔

² **Referenzinstallation, 13.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↔

11 · Datenschutz

zollsoft-Pfade: Modelle laufen nicht lokal; Zero-Data-Retention-Vertrag und EU-Hosting mit Mistral und Google. Anonymisierung danach nicht erforderlich; Patienten gegebenenfalls informieren, im Übrigen Verweis auf den eigenen Datenschutzbeauftragten. ¹

Tatsachenfeststellung aus der Messung: Die HTTP-Antwort enthielt ein `Set-Cookie` für `.generativelanguage.googleapis.com` — die Anfragen gehen an Googles Generative Language API. ²

Keine Bewertung; gehört dem Datenschutzbeauftragten vorgelegt. Bis zu einer dokumentierten Freigabe gilt am Endpunkt: **nur synthetische Demoakten, keine echten Patientendaten.**

Externe Modelle ausserhalb tomedos: Ein Forumsteilnehmer hält Anonymisierung vor Übergabe an ein externes LLM für nicht ausreichend. Laienaussage. ³ — betrifft unsere Arztbrief-Strecke.

BELEGE ZU DIESEM KAPITEL

- ¹ **Hersteller, 22.10.2025** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↔
- ² **Referenzinstallation, 13.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↔
- ³ **Fremdbericht, 23.10.2025** Erfahrungsbericht aus dem Nutzerforum, nicht bestätigt Quellenregister A.2 ↔

13 · Welcher Pfad wofür




Abb. 9 Pfadwahl für Fortgeschrittene

Aufgabe	Pfad
Reha- und Klinikbriefe strukturieren	(KI-)Zusammenfassung testen
Physio-Dokumentation aus dem Gespräch	Sprechstunden-Assistent
Ämteranfragen	LLM-Textgenerator mit eigenem Kontext
Arztbrief, überschaubarer Zeitraum	LLM-Textgenerator
Arztbrief aus Mehrjahres-Akte	extern, bis T1 und §10 geklärt
Posteingang stapelweise	Endpunkt-Pfad, solange F7 offen — 2,7 Aufrufe/min einplanen, <code>reasoning_effort: minimal</code>
Festes Ausgabeformat, maschinelle Weiterverarbeitung	Endpunkt mit Pro plus <code>reasoning_effort: minimal</code>

14 · Grenzen und Fehlerquellen

Systemgrenzen

GRENZEN – UND WAS DAS FÜR SIE HEISST

Bestätigungsdialog beim KI-Prompt manuell	1
--	---

Kartei-Chat und Sprechstunden-Assistent nicht auf iOS	1
--	---

Nur reine Textbausteine als Prompts	1
-------------------------------------	---

Nur Text-Karteieinträge in Assistenten- Vorlagen	1
---	---

Formular-Vorbefüllung nur AU (1/E) und Überweisung (6/E)	1
---	---

(KI-)Zusammenfassung: festes Schema, kein Anlernen	1
---	---

Textgenerator: Vorlage kappt auf 14 / 30 Einträge	2
--	---

Textgenerator schreibt nicht in die Kartei	2
--	---

Der Kartei-Abruf kennt nur eine Datumsgrenze, keinen inhaltlichen Filter	3
---	---

Karteieintrag bearbeiten heisst ersetzen	3
--	---

Schreib-Tools verlangen Inhalt ohne Quellenverweise	3
--	---

„Zurückschreiben" nur auf den jüngsten Karteieintrag	4
---	---

Karteieintragstyp und -datum per AK nicht änderbar	4
---	---

Die beiden letzten sind Anwendererfahrung, nicht Herstellerzusage.

Inhaltliche Fehlerklassen

Klasse	Gegenmassnahme
Zahlen-Konfabulation aus Mengen- und Dosisangaben	Stichprobe gegen die Quelle
Verborgene Abrufebene — „nicht dokumentiert“ heisst „nicht dort, wo ich gesucht habe“	Anhänge ausdrücklich ansprechen; jede Faktenfrage doppelt auswerten, gegen den Karteitext und gegen die ganze Akte [Referenzinstallation, 22.09.2026]
Keine Plausibilitätsprüfung — 1 von 98 Läufen	Aktenzahlen bleiben prüfpflichtig; der Chat bestätigt sie nicht. Reparierbar nur durch Verankerung plus ausdrücklichen Prüfauftrag [Referenzinstallation, 22.09.2026]
Das Einschränkende verschwindet beim Verdichten — Termine 19/20, Vorbehalte 1/25	Vorbehalte und stehende Angebote ausdrücklich anfordern; Termine nicht [Referenzinstallation, 22.09.2026]
Quellenkürzel sind kein Beleg	Zitatzwang setzen (37/38 zeichengenau); das Zitat mit der Gegenprobe aufschlagen [Referenzinstallation, 22.09.2026]
Behandler-Attribution	nie ungeprüft übernehmen ⁵
Selbstverifikation täuscht	Selbstauskunft ist kein Prüfergebnis
Stiller Inhaltsverlust bei Strukturabweichung	Gliederungsachse vorgeben, Vollständigkeit separat prüfen ⁶
Streuung zwischen Läufen	zwei bis drei Wiederholungen, Diff als Prüfliste
Leere Antwort trotz HTTP 200	<code>finish_reason</code> prüfen, fehlendes <code>content</code> abfangen ⁶
Kleine Stichprobe täuscht	mindestens 15 Läufe je Arm, Streuungsmasse mitberichten ⁶
Ausreissergetriebene Kennzahlen	nicht nur Latenz — auch Kosten je Lauf waren bei n=5 um 70 % verzerrt ⁶
Abbruch eines Messlaufs greift nicht	Abbruchweg testen, bevor er gebraucht wird; harten Kostendeckel einbauen ⁶
Aussage ohne Quellenverknüpfung	verifikationspflichtig ¹

Der stille Inhaltsverlust

Ein Flash-Lauf erfüllte **formal alle sechs Kriterien** und liess trotzdem **einen von drei geforderten Inhaltsblöcken komplett weg**, weil er die Rubriken nach einer anderen Achse schnitt und die geforderte Rubrikzahl damit auffüllte. In einer Reihe über 20 Läufe trat das mehrfach auf, ohne dass die formalen Kriterien es erfasst hätten. ⁶

HINWEIS **Zwei Regeln:** 1. **Die Gliederungsachse gehört in die Strukturvorgabe.** Eine Zahl allein ist erfüllbar, ohne die Aufgabe zu erfüllen. 2. **Vollständigkeit ist ein eigenes Prüfkriterium,** getrennt von der Frage, ob das Ergebnis richtig ist.

Beides ist in `karteichat-prompting` als benannte Modellgrenze aufgenommen; die Messmethodik steht in `tomedo-llm-endpunkt/references/betrieb-und-messung.md`.

BELEGE ZU DIESEM KAPITEL

- 1 **Hersteller, 11.09.2026** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters Quellenregister A.1 ↵
- 2 **UI, 13.09.2026** Erhebung aus der laufenden Instanz, tomedo v1.170.0.16 Quellenregister A.3 ↵
- 3 **Export, 13.09.2026** Tool-Export der eigenen Installation Quellenregister A.3 ↵
- 4 **Fremdbericht, 10.09.2026** Erfahrungsbericht aus dem Nutzerforum, nicht bestätigt Quellenregister A.2 ↵
- 5 **Referenzinstallation, 08.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↵
- 6 **Referenzinstallation, 13.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↵

15 · Offene Fragen

Nr.	Frage	Status
F1	Wirkt ein stärkeres Modell?	beantwortet — kein Unterschied in der fachlichen Richtigkeit, nur in Formattreue und Konstanz; der n=5-Erstbefund war falsch
F2	Modell- gegen Orchestrierungseffekt	offen — der Chat-Arm fehlt
F3	Stapelpfad über Statistik plus AK	eingeschränkt durch F7
F4	Endpunkt aus Hintergrundprozess erreichbar	beantwortet §8 — launchd Aqua, HTTP 200; Systemdomäne als F21 offen
F5	Reicht das 5-\$-Limit?	teilweise Teil 4 — es bremst nicht beim realen Verbrauch; ob es für Stapelbetrieb reicht, hängt an F19
F6	Anonymisierungs-Gate im Arztbrief-Pfad	Datenschutzbeauftragter
F7	Wann erscheint der Bestätigungsdialog?	blockierend für F3
F8	Welche Modelle sind für den Chat wahlbar?	eine E-Mail
F9	Leistet die (KI-)Zusammenfassung genug?	vor jedem Eigenbau
F10	Ersetzt der Sprechstunden-Assistent die <code><audio-*></code> -Prompts?	offen
F11	Ist der Marker-Pfad überholt?	beantwortet — <code>karteieintrag.autoquelle</code> trägt das KI-Flag, <code>llmcall</code> die Telemetrie je Modellaufruf
F22	Sieht der Chat Formulare, Rezepte, AU-Bescheinigungen, Leistungsziffern, Laborwerte?	neu — nicht gemessen. Die Testakten enthalten keine. Das ist die größte offene Lücke: „nicht dort, wo ich gesucht habe“ ist bisher nur an <i>einer</i> verborgenen Ebene belegt
F23	Setzen KI-Prompts aus Aktionsketten das Flag <code>autoquelle</code> ?	neu — bleibt es leer, untererfasst jede KI-Kennzahl systematisch
F24	Löst ein per Chat angelegter Eintrag Aktionsketten oder Leistungen aus?	neu — nicht geprüft. Schreibpfad insgesamt mit n=1 gemessen
F12	Aktuelle Modellliste	Methode gefunden (422-Test)
F13		offen

Nr.	Frage	Status
	Mindest-tomedeo-Version für den Endpunkt	
F14	PatientID/BesuchID-Bedingung	unbelegt
F15	Was ist hinter <code>GenerateContextText</code> ?	beantwortet §3 — der LLM-Textgenerator
F16	Herkunft der <code>total_tokens</code> -Differenz	beantwortet — Denk-Tokens
F17	Ist das Tool-Inventar installationsabhängig?	offen
G1– G6	Reichweite der generischen Objektebene, inkl. CKE	neu — Testreihe im Skill
T1– T7	Textgenerator: Kappung, Makros, Modell, Reproduzierbarkeit	neu — T1 und T7 entscheiden
F18	Maximale Promptgröße am Endpunkt	neu — entscheidet den Aktenbetrieb
F19	Was zählt tatsächlich auf das 5-\$-Limit an?	neu — Frage an zollsoft
F20	Mistral-Modelle und <code>flash-lite</code>	neu — nicht gemessen, keine Preise hinterlegt
F21	LaunchDaemon in der Systemdomäne, ohne Anmeldung	neu — blockiert den unbeaufsichtigten Nachtlaf

16 · Konsequenzen für laufende Vorhaben

Vorhaben	Konsequenz
/arztbrief -Skill	Der LLM-Textgenerator kann ihn für Briefe aus überschaubaren Zeiträumen ersetzen — ohne Anonymisierungsaufwand. Für Mehrjahres-Verdichtung entscheidet T1 (Kappung) und T7 (Reproduzierbarkeit). Erst messen, dann ersetzen.
Physio- <audio- * -Prompts	Sprechstunden-Assistent vergleichen
Physio- Textbausteine mit Dialog	Als Chat-Prompts unbrauchbar — zweite Fassung
Batch-Daemon	KI-Prompt-Pfad fällt aus, solange F7 offen; Endpunkt bleibt — aber mit 2,7 Aufrufen/min , eigener Kostenkontrolle und <code>reasoning_effort: minimal</code> . F21 vor dem unbeaufsichtigten Nachlauf klären
Marker-Pfad	Zurückstellen bis F11
CKE- Automatisierung	Testreihe G1–G6 fahren, bevor etwas gebaut wird
Benchmark- Methodik	Prüfraster um Vollständigkeit erweitern; mindestens 15 Läufe je Arm , Streuungsmasse mitberichten, Blindbewertung mit getrenntem Zuordnungsschlüssel; jede kostenverursachende Messung mit hartem Kostendeckel und getestetem Abbruchweg
Kostenrechnung	Überall, wo <code>cost</code> als Verbrauchsmass diente, auf die Denk-Token-Rechnung umstellen
Skills	<code>tomedo-llm-endpunkt</code> ist der zuständige Träger für \$8 , Teil 4 und die Messmethodik — Navigator plus fünf Referenzdateien. Dazu vier Updates: <code>tomedo-navigation</code> (AppleScript-Rezeptbuch, Format-Menü), <code>karteichat-prompting</code> (Werkzeugebene, Textgenerator, stiller Inhaltsverlust, G1–G6), <code>tomedo-aktionsketten</code> (KI-Prompt-Aktion), <code>tomedo-textbausteine</code> (Chat-Prompt-Regeln)

Anhang A · Quellen

Jede Quelle trägt eine Kennung. Über die Spalte *Kapitel* führt der Weg zurück in den Text, über Link beziehungsweise Ablageort zum Original.

A.1 · Hersteller — Onlinehilfe

ID	Seite	Belegt	Abruf	Kapitel
Q-H1	tomedo Intelligence — Übersicht (https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/)	Landkarte der KI-Oberflächen; nicht für tomedo iOS	11.09.2026	1
Q-H2	Kartei-Chat (https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/karteichat/)	Zweckbestimmung, Quellenverknüpfung, Lese- und Schreibumfang, CKE-Regeln, Prompts als Textbausteine, Promptverwaltung, Modellwechsel über den Support	11.09.2026	4, 9, 10
Q-H3	Sprechstunden-Assistent (https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/sprechstunden-assistent/)	Vorlagenaufbau, Beschreibung je Karteieintrag, Formatierungsregeln, neues Analyseverfahren	11.09.2026	6
Q-H4	(KI-) Zusammenfassung (https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/ki-zusammenfassung/)	Beta-Status, festes Schema, kein Anlernen	11.09.2026	7
Q-H5	Hilfe & Supportkontakt (https://support.tomedo.de/handbuch/tomedo/tomedo-intelligence/hilfe-supportkontakt/)	KI-Soforthilfe, Wissensbasis, Verbot der Eingabe von Patientendaten	11.09.2026	8
Q-H6	Aktionsketten, -auslöser, -bedingungen und -fragen (https://support.tomedo.de/handbuch/tomedo/automatisierung/aktionsketten-ausloeser-bedingung-fragen/)	Aktion „KI-Prompt“, Ergebnisweitergabe, Bestätigungsdialog	11.09.2026	5
Q-H7	KI-gestützte Erstellung von tomedo-Objekten (experimentell) (https://support.tomedo.de/handbuch/tomedo/automatisierung/lms-als-konfigurationshelfer/)	Konfigurationshelfer — im Handbuch genannt, nicht ausgewertet	11.09.2026	1
Q-H8	Textbausteine — Expertenfeature Frage-Antwort-Dialoge (https://support.tomedo.de/handbuch/tomedo/automatisierung/textbausteine/expertenfeature-konfiguration-von-frage-antwort-dialogen/)	Makro-Syntax, die in Chat-Prompts nicht ausgeführt wird	11.09.2026	4
Q-H9	Changelog Client v1.170.0.16 — Server v1.170-s1356 (https://support.tomedo.de/handbuch/tomedo/)	Versionsstand, auf dem sämtliche eigenen Messungen laufen	13.09.2026	alle ¹

ID	Seite	Belegt	Abruf	Kapitel
	changelog/tomodo-client-v1-170-0-16-server-v1-170-s1356/)			

A.2 · Nutzerforum

Erfahrungsberichte, keine Zusage.

ID	Thread	Belegt	Datum	Kapitel
Q-F1	106811 · KI-Nutzung überall in tomedo per API — Anleitung (https://forum.tomodo.de/index.php/106811/ki-nutzung-uberall-in-tomodo-per-api-anleitung)	Endpunktschema, curl-Vorlage mit dem messages-Objekt-Fehler; Modellwahl im Chat (überholt); Pro-Latenz 18.09.2025 (widerlegt); Kosten 16.09.2025; Datenschutz 22.10.2025; AppleScript-Anleitung 09.09.2025; Prompt-Vorselektion 10.09.2025	17.10.2025	11, Teil 4
Q-F2	109465 · KI-Nutzung DSGVO-konform über den zollsoft-eigenen LLM-Service (https://forum.tomodo.de/index.php/109465/ki-nutzung-dsgvo-konform-uberall-in-tomodo-per-zollsoft-eigenem-llm-service-anleitung)	DSGVO-Fassung der Anleitung; Laienaussage zur Anonymisierung vor externen Modellen	23.10.2025	11
Q-F3	114946 · Fehlermeldung bei KI-Aufruf per API (https://forum.tomodo.de/index.php/114946/fehlermeldung-bei-ki-aufruf-per-api)	HTTP 404 mit Authentifizierungshinweis, serverseitig behoben — nicht selbst nachgemessen	01/2026	8
Q-F4	124592 · Sehr variable Qualität der KI-Prompt-per-Aktionskette-Funktion (https://forum.tomodo.de/index.php/124592/sehr-variable-qualitat-der-ki-prompt-per-aktionskette-funktion)	Fremdbeobachtung zur Streuung; deckt sich mit der eigenen Messung der Ausgabelängen-Streuung	—	9, 14
Q-F5	125081 · Automatisierte Dokumentenanalyse, aktionskettengesteuert (https://forum.tomodo.de/index.php/125081/automatisierte-dokumentenanalyse-per-ki-aktionsketten-gesteuert)	Marker- und Regex-Pfad; Grundlage der offenen Frage F11; Zurückschreiben nur auf den jüngsten Karteieintrag	10.09.2026	5, 14

A.3 · Eigene Messungen und Erhebungen

Alle Messungen liefern gegen tomedo v1.170.0.16 (Client) / v1.170-s1356 (Server).

ID	Erhebung	Stand	Umfang und Befund	Ablage
Q-M1	Tool-Export der eigenen Installation	13.09.2026	Struktur der Werkzeugebene: Lese-, Schreib-, Bedien- und allgemeiner Datenzugriff; Datumsgrenze statt Inhaltsfilter beim Kartei-Abruf; eigener Zusammenhang der Anhangsanalyse	<code>_CHANGELOG_LLM-Werkzeugebene-Werkzeugebene-und-Skill-Freigabe-prompting/references/llm-tool</code>
Q-M2	A/B-Messreihe am LLM-Endpoint	13.09.2026	2 Modelle × 20 Läufe, identischer Fachprompt; 40 maschinell auf Form geprüft, davon 10 verblindet fachlich bewertet (5 je Arm); Latenz, Streuung, Formattreue, Kosten	<code>Skill-Qualitaetsgate-LLM-Endpoint/endpoint/references/modellwahl-messung.md</code>
Q-M3	Parameter- und Routensondierung am Endpoint	13.09.2026	Positivliste der akzeptierten Parameter, wirkungslose Parameter, HTTP-400-Kandidaten; neun geprüfte Routen, alle außer chat/completions mit HTTP 404	<code>tomedo-llm-endpunkt/reference-und-fehlerdiagnose.md</code>
Q-M4	Lasttest Kostenlimit	13.09.2026	74 Aufrufe an einem frischen Testnutzer, beendet vom eigenen Kostendeckel; reale 5-\$-Marke bei Aufruf 36, danach 38 weitere Aufrufe fehlerfrei; 1 008 495 Denk-Tokens folgenlos	<code>tomedo-llm-endpunkt/reference</code>
Q-M5	launchd-Erreichbarkeitstest	13.09.2026	Aufruf aus einem LaunchAgent ohne Terminal, Aqua-Domäne, HTTP 200 in 0,82 s; Systemdomäne ungetestet (F21)	<code>tomedo-navigation/references</code>
Q-M6	UI-Erhebung LLM-Textgenerator	13.09.2026	Zwei Bildschirmfotos des Fensters; System-Prompt mit sieben Regeln, Vorlagentext mit den Kappungswerten 14 und 30, Makro-Hinweis, Schaltflächen	<code>karteichat-prompting/references</code> (Testliste T1–T7)
Q-M7	Kontrollierte KarteiChat-Testserie	08.09.2026	Synthetische Demoakte mit 108 Karteieinträgen, 8 Prompt-Varianten, je 3–4 Läufe, rund 40 protokollierte Antworten; Fehlerkatalog Anker/Vorbehaltssatz/Typdefinition	<code>KarteiChat-Benchmark-Wiederholte-Auswertung_Akte1_2026-09-01.references/anker-guard-typdef</code>

ID	Erhebung	Stand	Umfang und Befund	Ablage
Q-M8	Arztbrief-Korpus und Reproduzierbarkeitsreihe	08/2026	Exportkorpora v25 und v26 in Voll-, 4-Quartals- und 8-Quartals-Schnitt; neun Läufe zur Reproduzierbarkeit; Grundlage des Vergleichs mit dem Textgenerator	arztbrief_export_korpus_v26_2 claude_arztbrief_reproduzierb
Q-M9	Summenbilanz aller Endpunkt-Aufrufe	13.09.2026	164 ausgeführte Aufrufe, davon 116 vollständig als Datei gesichert und nachlieferbar; sämtlich gegen tomedo v1.170.0.16	Rohdaten liegen praxisintern, nicht
Q-M10	Sondenreihe Textbaustein-Dialoge (Sonde C)	15.09.2026	14 Prüfzeilen in einem Wegwerf-Baustein, ein Durchlauf plus Einzelnachtests; Optionskatalog belegt, <code><zsUserText></code> -Semantik invers zur bisherigen Annahme, Keyword <code>REUSEANSWER</code> gefunden, <code>TRIMANSWER</code> und <code>SKIPDIALOGIFEXACTLYONEANSWER</code> ohne Wirkung, Formatierung überlebt nur an Antwortoptionen	tomedo-textbausteine/SKILL.m

A.4 · Anleitungen als Belegträger

Die Anleitungen aus Teil 3 sind keine eigenständige Quelle, sondern die geordnete Fassung der Messungen aus A.3.

HINWEIS Aussagen mit dem Status *plausibel* sind abgeleitet und tragen bewusst keine Quelle. Die Testreihen G1–G6 und T1–T7 sind geplant, aber nicht gefahren — siehe §15.

BELEGE ZU DIESEM KAPITEL

1 Referenzinstallation eigene Messung mit protokollierten Läufen Quellenregister A.3 ↗

TEIL 3 · KONFIGURIEREN

Teil 3 · Konfigurieren

alle, die tomedo konfigurieren — Praxismanagement, Projektverantwortliche, interessierte Anwender · Version v2.0 · Stand 2026-09-15 · Grundlage tomedo v1.170

Worum es hier geht. Um neun vorbereitete Arbeitsanleitungen, mit denen eine KI außerhalb von tomedo bei der Konfiguration hilft: Briefvorlage bauen, Aktionskette entwerfen, Formular vorbereiten, Auswertung aufsetzen, Prompt für den Kartei-Chat schreiben. Diese Anleitungen sind der Grund, aus dem es diese Sammlung gibt. Teil 1 und Teil 2 sind der Unterbau für alle, die neu mit der KI in tomedo arbeiten.

Für wen. Für alle, die über die Bedienung hinausgehen wollen. Programmierkenntnisse sind nicht nötig, Bereitschaft zum Testen schon.

Verhältnis zur Onlinehilfe. Die Onlinehilfe des Herstellers beschreibt, **was** eine Funktion tut und wo sie liegt. Sie ist gut, sie ist aktuell, und sie wird hier nicht nachgeschrieben. Was diese Sammlung hinzufügt, sind **Anwendungstipps aus dem täglichen Gebrauch**: welche Formulierung trägt, welche kippt, woran man ein falsches Ergebnis erkennt, welche Sackgasse man sich sparen kann. Ergänzung, nicht Ersatz — und ausdrücklich zur Übernahme durch den Hersteller gedacht.

1 · Das Problem, das Skills lösen

Eine allgemeine KI weiß nichts über tomedo. Sie kennt keine Briefkommandos, keine Aktionsketten, keine Karteieintragstypen. Fragen Sie sie danach, bekommen Sie eine Antwort, die plausibel klingt und erfunden ist — mit Platzhaltern, die es nicht gibt, und Menüpfaden, die nirgendwohin führen.

Man kann dagegen anschreiben: bei jeder Frage die Syntax mitschicken, die Regeln wiederholen, die bekannten Fallstricke aufzählen. Das funktioniert und ist mühsam. Nach dem zehnten Mal kopiert man einen halben Roman in jedes Chatfenster.

Ein **Skill** ist genau dieser Roman — einmal geschrieben, dauerhaft hinterlegt, und die KI greift von selbst darauf zu, wenn die Frage dazu passt.




Abb. 10 Mit und ohne hinterlegte Anleitung

2 · Skill, Gem, Custom GPT — dasselbe Prinzip, drei Namen

Alle drei großen Anbieter bieten dieselbe Grundfunktion an: **eine hinterlegte Arbeitsanleitung, die bei passender Frage automatisch greift**. Die Namen und ein paar Eigenschaften unterscheiden sich.

	Skill	Gem	Custom GPT
Anbieter	Claude (Anthropic)	Gemini (Google)	ChatGPT (OpenAI)
Was Sie hinterlegen	Anleitung plus beliebig viele Begleitdateien	Anleitung plus einige Dateien	Anleitung plus Dateien
Greift automatisch	ja, anhand der Beschreibung	nur wenn Sie das Gem öffnen	nur wenn Sie den GPT öffnen
Mehrere gleichzeitig	ja, mehrere Skills in einem Gespräch	nein	nein
Weitergabe	als Datei oder über die Organisation	über einen Link	über einen Link oder öffentlich
Eignung für Nachschlagewerke	sehr gut, auch bei großem Umfang	begrenzt	begrenzt

Was das praktisch heißt. Die hier beschriebenen Anleitungen sind für den Skill-Mechanismus gebaut: ein kurzer Steuerteil, der entscheidet, welche Begleitdatei gebraucht wird, und daneben die eigentlichen Nachschlagewerke. Ein Nachschlagewerk mit mehreren tausend Zeilen ist als Gem oder Custom GPT nur eingeschränkt nutzbar — es passt entweder nicht hinein oder wird nicht zuverlässig gelesen.

Wer mit Gemini oder ChatGPT arbeitet, nimmt deshalb sinnvollerweise den Steuerteil und die ein bis zwei Begleitdateien, die für die eigene Aufgabe zählen, statt der ganzen Sammlung.

3 · Bevor Sie anfangen: drei harte Punkte

Keine Patientendaten. Was Sie in eine öffentliche KI schreiben, verlässt die Praxis. Ohne Auftragsverarbeitungsvertrag mit dem Anbieter gehören dort weder Namen noch Geburtsdaten noch Befundtexte hinein — auch nicht gekürzt, auch nicht als Beispiel. Die Skills sind so gebaut, dass sie ohne echte Daten arbeiten: Sie beschreiben die Aufgabe, nicht den Fall.

Der Skill weiß nicht, wie es bei Ihnen aussieht. Er kennt Syntax, Regeln und bekannte Fehler — nicht Ihre Karteieintragstypen, nicht Ihre Formularnamen, nicht Ihre Versionsstände. Was er liefert, ist ein Entwurf, der zu Ihrer Installation passen muss.

Testen bleibt Ihre Aufgabe. Eine Briefvorlage, eine Aktionskette und eine Abfrage werden getestet, bevor sie produktiv gehen. Ein Skill verkürzt den Weg dorthin, er ersetzt den Test nicht.

4 · So arbeiten Sie mit einem Skill

1. **Skill einbinden.** Als Datei hochladen oder über die Organisation bereitstellen lassen. Danach ist er in jedem Gespräch verfügbar.
2. **Aufgabe beschreiben, nicht Lösung bestellen.** „Ich brauche im Arztbrief den Wert aus Feld X“ führt weiter als „schreib mir ein Briefkommando“.
3. **Gegenfragen zulassen.** Die Skills sind so angelegt, dass sie bei unklarer Vorgabe nachfragen, statt zu raten. Eine Rückfrage ist kein Umweg.
4. **Ergebnis testen.** In tomedo, an einem Testfall, nicht am Patienten.
5. **Abweichungen zurückmelden.** Wenn etwas in Ihrer Installation anders ist, gehört das in den Skill — sonst wiederholt sich der Fehler.

Woran Sie merken, dass kein Skill greift. Die Antwort enthält Platzhalter oder Menüpfade, die es nicht gibt, oder sie beginnt mit einer allgemeinen Erklärung, was eine Praxissoftware ist. Dann ist der Skill nicht eingebunden oder Ihre Frage enthält keines seiner Stichworte — nennen Sie ihn beim Namen.

5 · Zwei Empfehlungen, die unabhängig vom Skill wirken

Beide kosten einmal fünf Minuten und wirken in jedem Gespräch.

1 · Einen kurzen Dauerauftrag im Profil hinterlegen. Alle drei Anbieter haben ein Feld für persönliche Vorgaben, die bei jeder Anfrage mitgelten. Drei Sätze genügen — und mehr sollten es nicht sein, denn dieser Text läuft bei **jeder** Iteration mit und verbraucht jedes Mal Verarbeitungsaufwand.

Bei unklarer oder umfangreicher Aufgabe: erst bis zu drei Rückfragen, dann liefern.
Knapp antworten, Markdown als Standard. PDF, Word, PowerPoint nur auf ausdrückliche Bitte.
Wenn sich meine Fragestellung oder mein Vorgehen verbessern lässt, sag es in einem Satz.

Was das bewirkt: Die KI rät seltener, liefert keine Dokumentformate, die niemand bestellt hat, und bringt nebenbei bei, wie man besser mit ihr arbeitet.

2 · Wissen als `.md` sichern, nicht als PDF oder Word. Was Sie behalten wollen — Ergebnisse, Entscheidungen, gefundene Fallstricke — legen Sie als einfache Markdown-Datei in den Projektkontext. Word und PDF müssen bei jedem Zugriff erst auseinandergenommen werden und kosten ein Vielfaches an Verarbeitung, ohne ein Zeichen mehr Inhalt zu transportieren. Markdown ist außerdem diff-bar: Sie sehen, was sich zwischen zwei Ständen geändert hat.

HINWEIS Beides zusammen ist der Unterschied zwischen einem Werkzeug, das jedes Mal bei null anfängt, und einem, das mitwächst.

6 · Der Katalog

Neun Anleitungen, sortiert nach dem, was im Alltag am häufigsten gebraucht wird. Jede nennt: wofür sie gedacht ist, woran sie sich orientiert, wofür sie **nicht** gedacht ist, und wie eine gute Frage an sie aussieht.

Download. Die Anleitungen liegen als Archiv im selben Repository wie diese Seite und lassen sich direkt in Claude, Gemini oder ChatGPT einbinden.

Aufbau. Jede Anleitung besteht aus einem Steuerteil und, wo nötig, aus Begleitdateien. Der Steuerteil ist kurz und entscheidet, welche Begleitdatei für die gestellte Frage gebraucht wird. Die Begleitdateien sind die eigentlichen Nachschlagewerke — Syntaxtabellen, Fehlerkataloge, erprobte Muster.

karteichat-prompting

Organisationsweit · baut auf: Teil 1 · Abschnitt 5 und 10 · Teil 2 · §2 und §4

Wofür. Fragen und Frageketten für den Kartei-Chat bauen und Fehlverhalten einordnen. Steuerteil mit Begleitdateien zu Vorgaben, Vorbehaltssatz, Typdefinition, Modellgrenzen und Testprotokoll.

Nicht dafür. Nicht für die Bedienung des Kartei-Chats selbst — die steht in der Onlinehilfe. Der Skill baut Fragen, er stellt sie nicht.

GREIFT BEI STICHWORTEN WIE

Prompt rutscht

Filter-Bruch trotz Regeln

Anker setzen

Output leer oder zu lang

Kartei wird nicht durchsucht

Anlage wird nicht gelesen

Aufbau. Navigator. Die SKILL.md enthält nur die Entscheidungslogik — welche Referenzdatei für welches Problem zu öffnen ist — und die vier Pflichtbestandteile einer Frage. Das Belegmaterial liegt vollständig in `references/`. Dadurch bleibt der Skill auch dann handhabbar, wenn mehrere Referenzen gleichzeitig relevant sind.

SO FRAGEN

BEISPIELFRAGE

„Baue mir eine Frage für den Kartei-Chat, die alle dokumentierten Therapieversuche der letzten zwei Jahre auflistet. Die Diagnosen gebe ich fest vor.“

Was dann passiert: Der Skill liefert einen Prompt mit allen vier Pflichtbestandteilen: eine Typdefinition, die „Intervention“ in die konkreten Karteieintragstypen übersetzt, einen Vorbehaltssatz zur vorgegebenen Diagnoseliste, eine ausdrückliche Anweisung, die Kartei zu durchsuchen — und die Warnung, dass die Zwölfmonatsangabe keine Abrufsteuerung ist, weil das Historien-Tool nur ein Mindestdatum kennt.

Besser nicht. „Frag den Kartei-Chat nach den Therapieversuchen.“ — der Skill hat keinen Zugang zu Ihrer Praxissoftware. Er liefert den Text, den Sie dort einfügen.

Greift auch dann, wenn nur ein Symptom genannt wird: „das Modell nennt ein falsches Datum“ oder „die Kartei wird nicht durchsucht“.

Datei	Zeilen	Inhalt
<code>anker-guard-typdefinition.md</code>	76	Die drei Bausteine mit Trefferquoten aus der kontrollierten Testserie: Typdefinition drei von drei richtig, leerer Platzhalter drei von drei falsch. Enthält die Formulierungsmuster.
<code>kommando-bibliothek.md</code>	107	Welche Briefkommandos sich als feste Vorgabe eignen, welche stille Leerwerte liefern, und die Reihenfolge: erst die Vorgabe, dann die Aufgabe.
<code>llm-textgenerator.md</code>	202	UI-Erhebung des Generators: System-Prompt im Wortlaut, Vorlagentext, Kappungswerte 14 und 30, Makro-Hinweis — plus die offene Testliste T1 bis T7.
<code>llm-toolebene.md</code>	376	Die Werkzeugebene nach Zugriffsarten, die Grenzen des Kartei-Abrufs, der eigene Zusammenhang der Anhangsanalyse, die Reichweite des allgemeinen Datenzugriffs — und der am 22.09.2026 verifizierte Schreibpfad.
<code>modellgrenzen-und-quellen.md</code>	130	Was das Modell nachweislich nicht leistet, wie die Quellenverknüpfung zu lesen ist — und die gemessenen Quoten aus 356 Läufen, nach Aufgabentyp geordnet.
<code>patterns.md</code>	138	Erprobte Muster und die Gegenbeispiele, die in Läufen gescheitert sind — überladene Frage, Verbot ohne Wortliste, feste Vorgabe ohne Vorbehaltssatz.
<code>testprotokoll.md</code>	82	Das Protokoll: Sollwerte zuerst aus dem Volltextexport ziehen, zwanzig Läufe für alles Produktionskritische, getrennte Wertung gegen Karteitext und gegen Anlagen.
<code>praxis-interna.md</code>	93	Die Stelle für Ihre eigene Erhebung: welche Briefkommandos in Ihrer Installation einen Wert liefern. Wird leer ausgeliefert.

tomedo-textbausteine

Organisationsweit · baut auf: Teil 1 · Abschnitt 5

Wofür. Textbausteine mit interaktiven Frage-Antwort-Dialogen bauen — und damit die Voraussetzung schaffen, dass Dokumentation **einheitlich und vollständig** entsteht. Daran hängt alles Weitere: Ein Verlaufseintrag, der jedes Mal dieselbe Gliederung und dieselben Begriffe trägt, lässt sich auswerten, in einen Brief ziehen und einer KI als Anker vorgeben. Freitext in wechselnder Form lässt das nicht zu.

Nicht dafür. Nicht für Briefvorlagen und nicht für Patientenformulare. Textbausteine sind das kleinste Element.

GREIFT BEI STICHWORTEN WIE

Baustein mit Auswahlfeldern bauen

Einzel- gegen Mehrfachauswahl

Standardtext bei leerer Auswahl

Trennzeichen zwischen Antworten

Fließtext statt Gliederung

Aktionskette aus einer Antwort starten

Antwort wiederbenutzen

Prompt als Textbaustein ablegen

Aufbau. Einzeldatei, keine Begleitdateien. Enthält den vollständigen Optionskatalog der Frage-Antwort-Dialoge — Mehrfachauswahl per Zirkumflex, `ISSINGLECHOICE` als Autosprung, `DIVIDER`, `FIRSTDIVIDER`, `LASTDIVIDER`, `PREFIXWHENCONTENT`, `SUFFIXWHENCONTENT`, `UNANSWEREDQUESTIONTEXT`, `REUSEANSWER`, Kurztext und Aktionskette je Antwort — sowie die abweichenden Regeln für Bausteine, die als KI-Prompt dienen. Der Katalog ist seit **15.09.2026 durch eine Sondenreihe belegt** (Q-M10); jede Option trägt ihren Messstand. `TRIMANSWER` und `SKIPDIALOGIFEXACTLYONEANSWER` sind im Herstellerhandbuch dokumentiert, zeigten in der Messung aber **keine Wirkung**.

Das Formatierungs-Gate. Bevor der Skill baut, fragt er, wie stark der erzeugte Karteieintrag gegliedert sein soll. Drei Stufen, eine bewusste Entscheidung:

Stufe	Ergebnis im Karteieintrag	Wofür geeignet
ohne	durchlaufender Fließtext, Antworten mit Trennzeichen aneinandergereiht	Befundtexte, die als Prosa in den Brief sollen
leicht	Absätze und Zeilenführung, keine Überschriften	Verlaufseinträge, die lesbar bleiben, aber nicht formell wirken sollen
stark	zusätzlich Zeichenformatierung — derzeit gesperrt , weil nur Fettschrift an Antwortoptionen überlebt und der Karteieintragstyp sie überschreiben kann	nichts, was später ausgewertet oder maschinell weiterverarbeitet wird — dafür gilt ohne

Der Punkt daran: Der Formatierungsgrad ist keine Geschmacksfrage, sondern entscheidet darüber, ob sich der Eintrag später weiterverwenden lässt. Wer auswerten oder in einen Brief ziehen will, braucht **ohne**; wer am Bildschirm lesbare Verlaufseinträge will, nimmt **leicht**.

SO FRAGEN

BEISPIELFRAGE

„Baue einen Textbaustein für die Verlaufsdokumentation Physiotherapie mit Auswahlfeldern für Behandlungsart und Ergebnis. Formatierung: stark, das soll später auswertbar sein.“

Was dann passiert: Der Skill liefert den Baustein mit Abschnittsüberschriften, Einzelauswahl dort, wo genau ein Wert gelten muss, Mehrfachauswahl mit Standardtext dort, wo eine leere Auswahl vorkommen darf — und den Hinweis, dass mehrere Optionen mit `<zsMacroOption>` verkettet gehören — bei doppelter `¥`-Klammerung zeigt tomedo den Konfigurationstext wörtlich als Schaltfläche an.

`ISSINGLECHOICE` und `UNANSWEREDQUESTIONTEXT` vertragen sich dagegen; das frühere Verbot ist gemessen widerlegt.

Besser nicht. „Baue mir denselben Dialog als Chat-Prompt.“ — Frage-Antwort-Makros werden im Chat nicht ausgeführt, sondern als Rohtext weitergereicht. Der Skill liefert dafür die dialogfreie Fassung mit `_____` als offener Stelle.

Die Freigabe für den Kartei-Chat ist getrennt von der für den Support-Chat und von der für Aktionsketten. Ein in der Promptverwaltung gelöschter Eintrag löscht den Textbaustein mit. Formatierung im Baustein trägt nicht: Ein Karteieintragstyp mit eigener Formatierung überschreibt sie, und beim Auslesen per Briefkommando kommt reiner Text an.

tomedo-statistik-hql

Organisationsweit · baut auf: Teil 1 · Abschnitt 5 · Teil 2 · \$5

Wofür. HQL-Statistik-Queries im PostgreSQL-Dialekt. Der Weg zu eigenen Auswertungen über den eigenen Datenbestand — und zum Stapelpfad Statistik-Ergebnisliste plus Aktionskette.

Nicht dafür. Nicht für Einzelfallauskünfte — dafür ist der Kartei-Chat da. Und nicht für Auswertungen, deren Fragestellung noch offen ist: Zeitraum, Nenner und Zielgröße müssen vorher feststehen.

GREIFT BEI STICHWORTEN WIE

Query bauen

Feld existiert nicht

Ergebnis unplausibel

JOIN zieht Dubletten

Stapelkandidaten selektieren

userid per Statistik ermitteln

Aufbau. Der umfangreichste Skill. Acht Referenzen, davon zwei Datenmodell-Fassungen: eine kuratierte und der vollständige Datenbank-Auszug. Enthält 46 dokumentierte Fehlerquellen aus realen Abbrüchen.

SO FRAGEN

BEISPIELFRAGE

„Ich brauche eine Liste aller Patienten mit mindestens drei Kontakten im Quartal.“

Was dann passiert: Der Skill liefert die Query samt validiertem JOIN-Pfad und ZS-Filter für den Zeitraum — und den Betriebshinweis, dass der Sprung von der Ergebnisliste in eine Aktionskette der belegte Weg für einen Stapellauf ist, der SQL-Zugriff für Ärzte dagegen gesperrt bleibt.

Besser nicht. „Wie viele Patienten habe ich so ungefähr?“ — ohne Zeitraum und Zählregel ist jede Zahl beliebig.

Der Einstieg in diese Sammlung: Angefangen hat alles mit Abfragen über den eigenen Datenbestand.

Datei	Zeilen	Inhalt
<code>datenmodell_ZOLLSOFT_DB-dump.md</code>	7914	Vollständige Tabellenreferenz aus dem Datenbank-Auszug – Nachschlagewerk, nicht zum Lesen.
<code>datenmodell.md</code>	1753	Kuratierte Tabellenreferenz mit den praktisch relevanten Feldern.
<code>query-bausteine.md</code>	973	37 bewährte Bausteine, von der Patientensegmentierung bis zur Leistungsauswertung.
<code>lessons-learned.md</code>	569	46 dokumentierte Fehlerquellen: Feld existiert nicht, Ergebnis unplausibel, JOIN zieht Dubletten.
<code>enums-und-funktionen.md</code>	432	Enum-Werte, Bitfelder und tomedo-eigene Funktionen.
<code>join-pfade.md</code>	355	Validierte Verknüpfungswege zum Patienten.
<code>zs-filter.md</code>	139	Syntax der dynamischen Benutzerfilter.
<code>llm-toolebene.md</code>	97	Objektintrospektion als Zweitquelle zum Datenmodell.

tomedo-aktionsketten

Organisationsweit · baut auf: Teil 1 · Abschnitt 9 · Teil 2 · \$5

Wofür. Aktionsketten, Auslöser, Bedingungen und Fragen konfigurieren — einschließlich der Aktion „KI-Prompt“ und der Ergebnisweitergabe an Folgeschritte.

Nicht dafür. Nicht für die Formulierung des KI-Prompts selbst — dafür `karteichat-prompting`. Dieser Skill baut die Kette darum herum.

GREIFT BEI STICHWORTEN WIE

Kette bauen

Auslöser konfigurieren

blockierend gegen nicht-blockierend

Duplikatschutz

Zurückschreiben

Debugging über Loglevel-Feinschaltung

Aufbau. Katalogskill. Vier Referenzen bilden die vier Konfigurationsebenen einer Kette ab; die fünfte behandelt ausschließlich die Aktion „KI-Prompt“ und deren Ergebnisweitergabe.

SO FRAGEN

BEISPIELFRAGE

„Baue eine Kette, die bei Eingang eines Fremdbefunds eine KI-Zusammenfassung anstößt und das Ergebnis als Karteieintrag anlegt.“

Was dann passiert: Der Skill baut die Kette und trennt dabei den blockierenden Schritt (Karteieintrag anlegen mit Popover) vom nicht-blockierenden in eine Unter-Aktionskette, setzt eine Sperrbedingung gegen Mehrfachauslösung — und weist darauf hin, dass der Bestätigungsdialog einen unbeaufsichtigten Nachlauf derzeit ausschließt.

Besser nicht. „Warum ist meine Kette langsam?“ — Laufzeitfragen gehören in ein Support-Ticket.

Vorlagen müssen vor der Kette existieren: Leistungs-, Diagnose-, Aufgaben- und Nachrichtenvorlagen.

Datei	Zeilen	Inhalt
<code>aktionstypen.md</code>	237	Vollständiger Katalog der Aktionstypen samt Angabe, welche blockierend sind und welche nicht.
<code>ausloser.md</code>	275	Alle Auslöser mit Feuerverhalten — einschließlich der Stammdaten-Trigger, die bei jeder weiteren Änderung erneut feuern.
<code>bedingungen.md</code>	254	Bedingungssyntax und der Operator-Fallstrick: Underscore in <code>\${if ...}\$</code> , camelCase in <code>%if(...)</code> , deutsche Labels in der UI.
<code>fragen.md</code>	197	Aktionskettenfragen, Antworttypen und ihre Weiterverwendung.
<code>ki-prompt-aktion.md</code>	194	Die Aktion „KI-Prompt“: Freigabe in der Promptverwaltung, Ergebnis in eigenem Kommando, Bestätigungsdialog, verkettete KI-Schritte.

7 · Eine eigene Anleitung bauen

Sie brauchen keine Programmierkenntnisse. Sie brauchen eine Aufgabe, die sich wiederholt, und die Bereitschaft, einmal aufzuschreiben, was Sie dabei jedes Mal neu erklären.

1. **Aufgabe abgrenzen.** Eine Anleitung, die alles kann, greift nirgends zuverlässig. Je enger, desto besser.
2. **Auslöserworte sammeln.** Mit welchen Worten beschreiben Sie und Ihre Kollegen diese Aufgabe? Genau die gehören in die Beschreibung, sonst wird die Anleitung nicht gefunden.
3. **Abgrenzung mitschreiben.** Wofür die Anleitung *nicht* gedacht ist, und welche andere stattdessen greift. Das verhindert die häufigste Fehlfunktion.
4. **Belege sammeln, nicht Meinungen.** Was Sie selbst geprüft haben, mit Datum. Was Sie vermuten, ausdrücklich als Vermutung.
5. **Fehler aufschreiben, die Sie gemacht haben.** Das ist der wertvollste Teil. Eine Anleitung, die zehn bekannte Sackgassen benennt, spart mehr Zeit als eine, die zehn Funktionen erklärt.
6. **An einem echten Fall testen.** Nicht an dem, für den Sie sie geschrieben haben, sondern am nächsten.

Zwei Fallstricke. Beispiele, die Sie in die Anleitung schreiben, tauchen in den Ergebnissen wieder auf — auch dann, wenn Sie das ausdrücklich verbieten. Verwenden Sie deshalb nur Beispieldaten, die im Ergebnis stehen dürfen. Und: Eine Anleitung ohne Abgrenzung greift auch bei Fragen, für die sie nicht gemacht ist, und antwortet dann falsch statt gar nicht.

8 · Grenzen

GRENZEN — UND WAS DAS FÜR SIE HEISST

Kein Zugriff auf Ihre Installation	Alles, was geliefert wird, ist ein Entwurf und muss getestet werden
Stand der Anleitung ist der Stand der Prüfung	Mit einem tomedo-Update kann eine Angabe veralten
Keine Patientendaten	Aufgaben beschreiben, nicht Fälle schildern
Belegt ist nicht dasselbe wie allgemeingültig	Die Angaben stammen aus einer Referenzinstallation; andere Konfigurationen können abweichen
Kein Ersatz für die Onlinehilfe	Was eine Funktion tut, steht beim Hersteller — hier steht, wie man sie benutzt
Anleitungen ersetzen keine Abstimmung	Wer eine Vorlage ändert, ändert sie für alle

9 · Rückmeldung

Diese Sammlung ist aus der Arbeit in einer Praxis entstanden und lebt davon, dass Abweichungen gemeldet werden. Nützlich sind vor allem drei Dinge: eine Angabe, die in Ihrer Installation anders ist; eine Sackgasse, die noch nicht dokumentiert ist; und ein Anwendungsfall, für den bisher keine Anleitung existiert.

Und ausdrücklich: **Der Hersteller darf alles hiervon übernehmen** — ganz, in Teilen, umgeschrieben. Was hier steht, ist der Versuch eines Anwenders, das Vorhandene besser nutzbar zu machen. Am besten aufgehoben wäre es im Herstellerhandbuch.

Noch ein Zusatz, der hier bewusst am Rand steht: Wer Skripte gegen den tomedo-Server schreibt, findet in Teil 4 · Der LLM-Service-Endpunkt die Schnittstellenkunde dazu. Für alle anderen endet die Sammlung hier.

TEIL 4 · NUR PRAXIS-IT

Teil 4 · Der LLM-Service-Endpunkt

Praxis-IT — nur wer Skripte gegen den Server baut · Version v1.0 · Stand 2026-09-15 ·
Grundlage tomedo Client v1.170.0.16 / Server v1.170-s1356

ACHTUNG **Zusatz für die Praxis-IT. Wer keine Skripte schreibt, hört hier auf.** Dieser Teil steht bewusst am Rand: Er beschreibt keine Funktion der Oberfläche, sondern eine Server-Schnittstelle, die jeder selbst bedienen muss.

Wozu es den Endpunkt gibt. Er stellt ein Sprachmodell über die **datenschutzkonforme Strecke des Herstellers** bereit — EU-Hosting, Zero-Data-Retention, keine eigene Vertragsbeziehung zu Google oder Mistral nötig. Das ist der eigentliche Wert: **ein DSGVO-tauglicher Modellzugang, ohne selbst einen Anbietervertrag zu schliessen.**

Was man dafür selbst mitbringen muss. Alles andere. Der Endpunkt sieht keine Akte, kennt keine Werkzeuge, hat keine Oberfläche und keine Kostenanzeige. Was das Modell wissen soll, muss in den Prompt; was das Ergebnis kostet, muss man selbst ausrechnen; was schiefgeht, steht in keinem Dialog, sondern in einem HTTP-Code.

Zuständiger Skill: `tomedo-llm-endpunkt` (Teil 3, Danger Zone).

Was ab hier folgt, betrifft den LLM-Service-Endpunkt: eine Schnittstelle am tomedo-Server, die von aussen per Skript angesprochen wird. Sie sieht keine Kartei und schreibt in keine. Fuer die Arbeit am Patienten ist nichts davon relevant.

1 · Aufruf, Routen, Parameter

Der einzige Pfad mit **freier Modellwahl je Anfrage** — und der einzige **ohne Werkzeugzugriff**. Er sieht keine Akte; alles, was das Modell wissen soll, muss in den Prompt.

```
{server_url}llmservice/{userId}/v1/chat/completions
```

Server-URL aus **tomedo** › **Über tomedo**, `userId` per Statistik `select Ident from Nutzer where Kürzel = 'XXX'`. Der Ident steht im Pfad und ist zwingend; **nie das Kürzel eines produktiv arbeitenden Nutzers**, das Budget hängt daran. Im offiziellen curl-Beispiel steht `"messages"` fälschlich als Objekt statt als Array. **Keine Werkzeuge**.¹

Es gibt genau diese eine Route. `/v1/models`, `/v1/models/{name}`, `/v1`, Wurzel, `/v1/embeddings`, `/v1/usage`, `/v1/limits`, `/usage`, `/limits` — alle HTTP 404.² Drei Folgen: **Modellliste nicht abfragbar** (Ersatzmethode: 422-Test, §9) · **Kontostand nicht abfragbar** · **keine Embeddings**, also kein RAG über diesen Weg. Auch **keine Kontingent-Header** — eine drohende Sperre ist nicht vorhersehbar.

Parameter — strenge Positivliste²

akzeptiert	akzeptiert, aber wirkungslos	HTTP 400
<code>temperature</code> , <code>top_p</code> , <code>stop</code> , <code>n</code> , <code>response_format</code> , <code>reasoning_effort</code> , <code>max_tokens</code>	<code>stream</code> , <code>tools</code>	<code>seed</code> , <code>presence_penalty</code> , <code>frequency_penalty</code> , <code>thinking_budget</code> , <code>extra_body</code> , jeder unbekannte Name

ACHTUNG `tools` erzeugt keinen Fehler, sondern eine frei erfundene Textantwort. Wer Werkzeuge definiert und auf Werkzeugaufrufe wartet, merkt das Scheitern nicht. Und: **der Antwortkörper der 400er ist leer** — er sagt nicht, welcher Parameter störte. Beim Bau eines Aufrufs Parameter **einzeln** zuschalten.

Gemessene Fehlerbilder²: leere Antwort → `-s` unterdrückt Fehler · **HTTP 422** **Unbekanntes Modell** als deutschsprachiger Klartext ohne JSON-Hülle · **HTTP 400 mit leerem Körper** → nicht unterstützter Parameter · HTTP 404 auf anderen Routen → **kein Fehler** · Timeout → nicht im Praxisnetz · **HTTP 200 ohne Feld** `content` → §2.

Nicht selbst gemessen, aus dem Forum übernommen: HTTP 404 mit Authentifizierungshinweis, serverseitig, 01/2026 behoben.³

HINWEIS **Fallstrick:** Forums-Beispiele enthalten fremde Hostnamen und Idents. Mit `curl -s` scheitert der Aufruf lautlos — immer `-i` oder `-w '%{http_code}'`.

Betrieb aus Hintergrundprozessen. Der Endpoint ist aus einem launchd-Job **ohne Terminal** erreichbar (Aqua-Domäne, HTTP 200, 0,82 s) — ein nächtlicher Stapellauf als LaunchAgent ist technisch möglich. ² **Nicht belegt** und vor Produktivnutzung einzeln zu prüfen: LaunchDaemon in der Systemdomäne, Lauf ohne angemeldeten Nutzer, Lauf bei gesperrtem Bildschirm (F21).

Durchsatzgrenze. Sechs parallele Fäden gegen Pro mit `reasoning_effort: high` brachten **2,7 Aufrufe/min** — die Latenz je Aufruf stieg dabei von 51 s im Einzelbetrieb auf rund 90 s. **Der Server serialisiert spürbar.** ² Für Stapelbetrieb heisst das: Mehr Parallelität löst das Zeitproblem nicht, der Hebel ist `reasoning_effort` (§2).

Keine Reproduzierbarkeit. `seed` wird mit HTTP 400 abgelehnt; 20 Läufe je Modell mit identischem Prompt ergaben 20 verschiedene Ausgaben. ²

Zuständiger Skill: `tomedo-llm-endpunkt` — fünf Referenzdateien zu Aufruf, Fehlerdiagnose, Kosten, Modellwahl und Messbetrieb. Die AppleScript-Klammer darum steht in `tomedo-navigation/references/applescript-rezeptbuch.md`.

Fehlerquellen am Endpoint

Aus dem Fehlerkatalog in §14 hierher verlagert.

Fehlerquelle	Beleg
Endpoint ohne Werkzeugzugriff	² bestätigt
Endpoint: <code>tools</code> und <code>stream</code> wirkungslos , kein Fehler	²
Endpoint: <code>seed</code> abgelehnt — keine Reproduzierbarkeit	²
Endpoint: keine Modellliste, kein Kontostand, keine Embeddings	²
Endpoint: <code>max_tokens</code> begrenzt Denken und Ausgabe zusammen	²
Endpoint: 5-\$-Limit greift nicht beim realen Verbrauch (10,10 \$ ohne Ablehnung); worauf es anrechnet, offen (F19)	²
Endpoint: Durchsatz 2,7 Aufrufe/min, Server serialisiert	²

BELEGE ZU DIESEM KAPITEL

- ¹ **Hersteller, 17.10.2025** Onlinehilfe oder Aussage eines zollsoft-Mitarbeiters [Quellenregister A.1 ↔](#)
- ² **Referenzinstallation, 13.09.2026** eigene Messung mit protokollierten Läufen [Quellenregister A.3 ↔](#)
- ³ **Fremdbericht, 01/2026** Erfahrungsbericht aus dem Nutzerforum, nicht bestätigt [Quellenregister A.2 ↔](#)

2 · Kosten, Denk-Tokens und Budget

HINWEIS **Korrektur gegenüber v0.4.** Dort stand, `total_tokens` sei unbrauchbar und es sei ausschliesslich `cost` zu verwenden. **Das ist invertiert.** Der Skill `tomedo-llm-endpunkt` belegt das Gegenteil, und zwar mit breiterer Datenbasis.

Jede Antwort enthält `cost` in USD und ein `usage`-Objekt. `total_tokens` liegt weit über der Summe aus `prompt_tokens` und `completion_tokens` — die Differenz sind **Denk-Tokens**. Das Feld `reasoning_tokens` steht dabei durchgängig auf 0 und meldet sie nicht.

1

`cost` rechnet nur `prompt + completion` — exakt nach Google-Listenpreis, auf die Stelle nachgerechnet. **Die Denk-Tokens bleiben unberücksichtigt, werden von Google aber zum Ausgabepreis berechnet.**

Fall	gemeldet	real	Faktor
Flash, Fachprompt	0,000778 \$	0,008490 \$	10,9×
Pro, Fachprompt	0,001446 \$	0,021100 \$	14,6×
Pro, Logikrätsel, hoher Denkaufwand	0,000255 \$	0,073995 \$	290×
Pro, 74 Aufrufe unter Last	0,01860 \$	10,104 \$	543×

HINWEIS **Regel: für Budgethochrechnungen nie `cost` allein.** Immer `total_tokens - prompt_tokens - completion_tokens` als Denk-Tokens zum Ausgabepreis mitrechnen.

Mittelwerte über n=20 je Arm — die Zeilen oben sind Einzelbelege der Preisnachrechnung:

Posten	Flash	Pro
<code>cost</code> je Lauf, gemeldet	0,000633 \$	0,001516 \$
tatsächlich inkl. Denk-Tokens	0,004930 \$	0,021412 \$
Untertreibungsfaktor	7,8×	14,1×
Läufe bis 5 \$ nach <code>cost</code>	rund 7900	rund 3300
Läufe bis 5 \$ tatsächlich	rund 1010	rund 230

Das 5-\$-Limit bremsst nicht. Belegt sind **10,10 \$** reale Kosten an einem frischen Nutzer bei **null Ablehnungen. Kostenkontrolle selbst bauen.**

Zur Hochrechnung aus v0.4 („rund 3450 beziehungsweise 6400 Läufe bis 5 \$“): Sie beschreibt, wie viele Läufe das Feld `cost` bis 5 \$ zulässt — nicht, was sie kosten. Real liegen 3300 Pro-Läufe bei rund 71 \$. **Ob das Limit an diese Zahl gebunden ist, ist offen (F19)** — v0.5 hatte sie vorschnell als „zu optimistisch“ verworfen, was nur zuträfe, wenn das Limit am realen Verbrauch hängt. Genau das ist widerlegt.

`reasoning_effort` ist der Hebel

`minimal` senkt die realen Kosten auf ein Viertel (Flash) bis Drittel (Pro) und die Latenz auf ein Drittel bis die Hälfte. **Die Formattreue hielt in der Stichprobe;** bei Flash bestanden ausgerechnet `minimal` und `low` die Strukturprüfung, während *ohne Zusatz* und `high` durchfielen. ²

Modell	Einstellung	Denk-Tokens	Latenz	real
Flash	ohne Zusatz	3024	17,3 s	0,00923 \$
Flash	<code>minimal</code>	817	5,9 s	0,00252 \$
Pro	ohne Zusatz	2380	19,9 s	0,02537 \$
Pro	<code>minimal</code>	741	8,0 s	0,00857 \$

Belastbarkeit: je ein Lauf pro Einstellung. Die Kosten- und Latenzeffekte sind zu gross für Zufall, die Qualitätsaussage ist es nicht.

Falle: `max_tokens` begrenzt Denken und Ausgabe zusammen

Es ist **keine** Ausgabelängenbegrenzung. Das Kontingent geht zuerst fürs Nachdenken drauf. ²

Aufruf	HTTP	<code>finish_reason</code>	Denk	Completion	Ergebnis
Flash, <code>max_tokens</code> 600	200	<code>length</code>	572	24	mitten im Satz abgeschnitten
Pro, <code>max_tokens</code> 600	200	<code>length</code>	597	0	kein Feld <code>content</code>
Pro, <code>max_tokens</code> 2000	200	<code>length</code>	1997	0	kein Feld <code>content</code>

ACHTUNG Stiller Fehlerfall. HTTP 200, winzige gemeldete Kosten — und im `message`-Objekt fehlt `content` **vollständig**, es ist nicht leer. Die übliche Ersatzkette greift deshalb nicht. **Immer `finish_reason` prüfen** und `max_tokens` bei Pro nicht ohne Not setzen: selbst 2000 Tokens reichten nicht für eine einzige Antwortzeile.

Zum 5-\$-Limit im Detail: Die reale 5-\$-Marke fiel bei **Aufruf 36**, danach liefen **38 weitere Aufrufe** fehlerfrei durch — rund **102 %** über der nominalen Grenze, ohne Sperre, ohne Warnung, ohne veränderte Answer-Header. Beendet wurde der Lauf vom eingebauten Kostendeckel, nicht vom Endpunkt. Insgesamt passierten **1 008 495 Denk-Tokens** folgenlos. Was stattdessen angerechnet wird, ist offen (F19).

Die Hochrechnung gilt nur für kurze Prompts. Bei grossen Prompts dominieren die Prompt-Tokens, die in `cost` voll enthalten sind — dort laufen gemeldete und reale Kosten wieder zusammen. Die **maximale Promptgröße** ist nicht gemessen (F18).

Vollständig: `tomedo-llm-endpunkt/references/kosten-und-budget.md`.

Do's und Don'ts am Endpunkt

✓ SO

- `reasoning_effort: minimal` in fast jeden Aufruf setzen — ein Drittel bis Viertel der realen Kosten, etwa die halbe Latenz.
- Immer `-i` oder `-w '%{http_code}'` verwenden.
- `messages` als Array übergeben — die offizielle Vorlage zeigt fälschlich ein Objekt.
- Einen Testnutzer-Ident verwenden, nie den eines produktiv arbeitenden Nutzers.
- Beim Bau eines Aufrufs die Parameter einzeln zuschalten.
- `finish_reason` prüfen und ein fehlendes `content` abfangen.
- Denk-Tokens selbst rechnen: `total_tokens` minus prompt minus completion.
- Für Stapelbetrieb 2,7 Aufrufe pro Minute einplanen.

× BESSER NICHT

- `curl -s` allein verwenden — Fehler verschwinden lautlos.
- `seed`, `presence_penalty`, `frequency_penalty`, `thinking_budget` oder `extra_body` mitschicken: HTTP 400 mit leerem Körper.
- Werkzeuge definieren und auf Werkzeugaufrufe warten — `tools` erzeugt keinen Fehler, sondern eine frei erfundene Textantwort.
- Auf Streaming setzen: `stream` wird stillschweigend ignoriert.
- `max_tokens` bei Pro ohne Not setzen — selbst 2000 Tokens reichten nicht für eine Antwortzeile.
- Sich auf das 5-\$-Limit als Bremse verlassen: 10,10 \$ liefen ohne eine einzige Ablehnung durch.
- Eine Modellliste oder einen Kontostand abfragen — beide Routen gibt es nicht.
- Echte Patientendaten senden, bevor eine dokumentierte Freigabe vorliegt.

Belege: Teil 2 · §11

BELEGE ZU DIESEM KAPITEL

- 1 **Referenzinstallation, Skill `tomedo-llm-endpunkt`** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↩
- 2 **Referenzinstallation, 13.09.2026** eigene Messung mit protokollierten Läufen Quellenregister A.3 ↩

tomedo-KI-Handbuch · Teil 1 v2.1 · Teil 2 v1.0 · Teil 3 v2.0 · Stand 2026-09-15. Ergänzung zur Onlinehilfe des Herstellers, kein Ersatz — Übernahme durch zollsoft ausdrücklich erwünscht. Alle Messangaben stammen aus einer Referenzinstallation (tomedo v1.170.0.16 / Server v1.170-s1356); andere Konfigurationen können abweichen. Diese Datei ist offline vollständig — sie lädt nichts nach.